CS5486 期中情报（2026-10 考后更新）：实际范围 = 开课→kWTA（**ART1 未考，ART 内容移至期末资料**）；半开卷**一张 A4 双面**；**实际题型 = 约 25% 网络对比 + 约 75% 推导计算**（期末暂定同比例）；一般无需计算器；期中占 30%。
符号：u=$\Sigma w_i x_i$；d 期望 / y 实际 / e=$d-y$；η 学习率；θ 阈值 ⇔ 偏置 $b=-\theta$, $x_0=1$。标记：推导 大题默写模板 对比 对比题 概念 填空/辨析。

弱项 ⚠ 易错急救卡（我的丢分点，先看这个）

①收敛定理必须答全三件事：**前提** linearly separable + **in a finite number of steps**（有限次更新）+ 结果得正确分类的 weights **and** threshold——漏前提或漏"有限" = 丢分。拼写：boundary（非 boundry）、in **a** finite number of **steps**。
②XOR 原因 = not linearly separable（正类两点对角，无直线可分）——**绝不是"权重数量/神经元数量不足"**！标准句：A single-layer perceptron can only form a linear decision boundary, but the XOR problem is not linearly separable.
③ADALINE 题必说 minimize the MSE：误差基于**线性输出** $y=w^Tx$（非二值输出）；**梯度 ≠ 误差函数本身**：$\nabla E=-\Sigma_p e_p x_p$，更新用梯度。
④对比题用完整句（主语 + 双方 + whereas）：The perceptron updates weights based on **classification errors**, whereas ADALINE uses **gradient descent** to minimize the mean squared error.
⑤细节分：η = learning rate，controls **the size of weight updates**（别写成 n，n 常是样本数）；batch 更新 Σ_p 别丢。

概念 1 · 基础速答

ANN=(ARCH, RULE)；ARCH=(u,v,w,x,y)；RULE=(E,F,G,H,L)：E 评价（误差/能量函数）、F 激活、G 聚合（加权和）、H 输出、L 学习（迭代调 w）。
分类四维度：确定性/随机（F）｜前馈/循环（G,H）｜半线性/高阶（G）｜有监督/无监督（L）。**短期记忆** = u,v 快动态；**长期记忆** = w 慢动态。
一般增量学习规则：$w(t+1)=w(t)+\eta\cdot r(x,y,d,w)$（连续 $\dot w=\eta\cdot r$）；一切规则皆为 r 的特例。
M-P 神经元（1943）：{0,1} 二值；权重 ±1；**抑制输入=1 ⇒ 输出必 0**；否则加权和 ≥θ ⇒ 1。三命题：①任意逻辑函数可由**两层** M-P 网实现；②无抑制连接只能实现**单调**逻辑函数；③任意有限自动机可由 M-P 循环网络模拟。
里程碑：43 M-P｜50s末 Rosenblatt 感知机｜60s Widrow ADALINE｜70s Zadeh 模糊·**Grossberg ART**·Kohonen SOM｜74 Werbos BP｜82 Hopfield｜86 PDP 推广 BP｜88 Broomhead&Lowe RBF｜90s Vapnik SVM｜06– Hinton DL；**2024 诺贝尔物理奖 = Hopfield & Hinton。**

推导 2 · Perceptron

2.1 输出规则 + 线性可分定义

单层自适应阈值逻辑单元前馈网（Rosenblatt，Cornell，1950s末，首个硬件实现）。$y=1 \iff u=\Sigma w_i x_i \ge \theta$，否则 0（hard-limit）。
线性可分（课件定义）：存在 n+1 个实权重（含阈值）使一组加权和恒 ≥（>）θ、另一组恒 <θ。有限集线性可分 ⇒ 绝对线性可分。

2.2 学习规则【默写】

仅当 y≠d 才更新：
$w_i(t+1)=w_i(t)+\eta(d-y)x_i$；$\theta(t+1)=\theta(t)-\eta(d-y)$
迭代学习（Lippmann）：d=1,y=0 → $w\leftarrow w+\eta x$, $\theta\leftarrow\theta-\eta$；d=0,y=1 → $w\leftarrow w-\eta x$, $\theta\leftarrow\theta+\eta$；正确不动。

2.3 收敛定理【英文必背】

If two sets of data are linearly separable, the perceptron learning algorithm converges to a set of weights and a threshold in a finite number of steps.
⚠ 三要素答全：**前提**线性可分 + **有限步** + 结果含 threshold（急救卡①）。不可分则不收敛（震荡）。

2.4 手推例：AND（η=1, W(0)=0, b=0）

逐样本错才更：6 轮收敛 $w=[2,1], b=-3$，边界 $2x_1+x_2-3=0$（四点全对 = 零误差区）。陷阱：(0,0) 首轮 y=1≠0 触发更新，但 x=0 ⇒ 权重不变、仅 b 动。

2.5 XOR + 权重空间几何

XOR 非线性可分 ⇒ 单层感知机/ADALINE ✗（⚠ **原因 = 非线性可分，不是权重/单元数量不足**，急救卡②）；**两层感知机、RBF、核SVM** ✓。局限：仅线性可分；高维/大样本收敛慢。
m 个样本画切 n 维权空间：区域数 = m 的 n−1 次多项式；1面→2，2→4，3→8，**4→最多14**。阈值函数 ~$O(2^{n(n-1)})$ ≪ 逻辑函数 2^{2^n} ⇒ **learnability 问题**（s114 两问：解在权空间是否存在？存在时如何求？——两层可分但缺学习算法）。
bipolar {−1,+1} 优于 unipolar {0,1}：代数结构更好 + 权空间可行区域占比更大。

推导 3 · ADALINE / LMS

定义：Adaptive Linear Elements（Widrow & Hoff，Stanford，60s 初）：单层**线性**单元，学习时 $y=w^Tx$。

LMS 四步推导【默写】

①目标：$E(w)=\frac{1}{2}\Sigma_p(d_p-w^Tx_p)^2$，$e_p=d_p-w^Tx_p$
②求导：$\nabla E(w)=-\Sigma_p e_p x_p$（$\partial E/\partial w_i=-\Sigma_p e_p x_{pi}$）
③下降 $w(t+1)=w(t)-\eta\nabla E$ ⇒ **④批量更新**
$w(t+1)=w(t)+\eta\Sigma_p e_p x_p$；序贯 Delta：$\Delta w=\eta e x$

训练模式（课件）：Perceptron 序贯或 batch 均可；**ADALINE 仅 batch**。η 过大→震荡，过小→极慢。⚠ **答题必带 minimize the MSE；误差基于线性输出**（急救卡③）。
一步数值例：x=[2,1]ᵀ, d=1, w=[0,0], η=0.1 ⇒ y=wᵀx=0, e=d−y=1, Δw=ηex=[0.2,0.1]ᵀ ⇒ w=[0.2,0.1]ᵀ（批量 = $\Sigma_p e_p x_p$ 累加）。**感知机对照**：同输入 d=1,y=0 ⇒ w←w+ηx, θ←θ−η（误分类驱动，非梯度）。

推导 4 · 多层前馈与 BP

4.1 一句话定义【英文】

Backpropagation (generalized delta rule, PDP 1986; Werbos 1974) is a recursive gradient-descent learning algorithm for multilayer feedforward networks of sigmoid activation functions; it computes error gradients backward from output to input layer to minimize the mean squared error. **BP 是算法非结构，≠ recurrent.**

4.2 Sigmoid 导数【必背】

单极 $\sigma(s)=1/(1+e^{-s})$，$\sigma'=y(1-y)$｜双极 $\sigma(s)=\tanh s$，$\sigma'=1-y^2$

4.3 三层 delta 链【默写】

记号：隐层 $z_j=\sigma(\Sigma_i v_{ij}x_i)$，输出 $y_k=\sigma(\Sigma_j w_{jk}z_j)$，$E=\frac{1}{2}\Sigma_p\Sigma_k(d_{pk}-y_{pk})^2$
①通用更新 $\Delta_p w_{jk}=\eta\delta_k z_j$（δ×该权输入信号）
②输出层（链式 $\partial E/\partial w=\partial E/\partial y\cdot\partial y/\partial s\cdot\partial s/\partial w$）：$\delta_k=(d_k-y_k)\cdot y_k(1-y_k)$
③隐层（上层 δ 按权回传求和）：$\delta_j=z_j(1-z_j)\cdot\Sigma_k w_{jk}\delta_k$
双极 sigmoid 时导数换 $1-y^2$。

四步：随机初始化→前向→反向逐层 δ→更新；循环至收敛。**动量**：$\Delta w(t)=-\eta\partial E/\partial w+\alpha\Delta w(t-1)$（0<α<1）防震荡。

4.4 理论三句话【概念】

Kolmogorov：$f(x)=\Sigma_{j=1}^{2n+1}g_j(\Sigma_i w_{ij}h_i(x_i))$ ⇒ MLP 是**通用逼近器**（存在权重使误差任意小）**但 BP 不保证找到**（局部极小）；**过拟合** = 训练好测试差；**一般学习问题是 NP-complete**（s187）。

推导 5 · RBF 网络

RBF：取值只依赖**到中心距离 r**；Gaussian 最常用；另有 MQ $\sqrt{(r^2+c^2)}$、逆MQ $1/\sqrt{(r^2+c^2)}$、薄板 $r^2\ln r$。

结构（Broomhead & Lowe 1988）：两层 = **隐层 RBF + 输出层线性**（同 ADALINE）
$\varphi_j(x)=\exp(-\|x-c_j\|^2/(2\sigma_j^2))$；$y=\Sigma_j w_j\varphi_j(x)+w_0$

Cover 定理【英文】：a complex pattern-classification problem, cast nonlinearity in a high-dimensional space, is more likely to be linearly separable than in a low-dimensional space（φ-separable：$w^T\varphi(x)>0$ / <0）。
RBF 解 XOR【例题】：$c_1=[1,1]^T$, $c_2=[0,0]^T$ 两高斯元 → 四点映到 (φ_1,φ_2) 面**线性可分**，线性输出层分类。
概念 **FLN**（Pao, CWRU, 80s末）：单层 + 高阶聚合（$x_i x_j$ 项），快、局部极小可消除。**ELM**（黄广斌, NTU, 2000s中）：输入→隐层权重**随机固定**，只解输出层最小二乘：极快、无局部极小。

5.5 常用激活函数速查【概念】

函数	式	导数	用于
hard-limit	$f(s)=1(s\ge\theta)$	—（不可微）	感知机/MAXNET
线性	$f(s)=s$	1	ADALINE/RBF输出
单极 sigmoid	$1/(1+e^{-s})$	$y(1-y)$	BP（可微）
双极 sigmoid	$\tanh(s)$	$1-y^2$	BP（对称）
高斯 RBF	$e^{\{-\|x-c\|^2/2\sigma^2\}}$	$-(x-c)/\sigma^2\cdot\varphi$	RBF 隐层

为何 BP 要可微：梯度下降需 $\partial E/\partial w=\partial E/\partial y\cdot\sigma'(s)\cdot$输入；hard-limit 在跳变点无导数 ⇒ 无法直接梯度训练（感知机只能用误分类规则）。

5.6 RBF 中心选择与训练实务【概念】

中心 c 选取：随机抽训练样本｜k-means 聚类｜正交最小二乘 (OLS)逐个加入｜全监督梯度同训（慢）。σ：按最近邻中心间距设定或交叉验证。**两阶段优势**：输出层线性 ⇒ 最小二乘**闭式解**（解线性方程组/伪逆），无局部极小、极快；缺点 = 维数灾难（高斯基随维数指数需更多中心）。

5.7 MLP+BP 训练实务【概念】

过拟合对策：early stopping（验证集误差回升即停）｜正则化（加 λ‖w‖²）｜减隐元｜增数据。**权重初始化**：小随机数（全 0 会因对称性卡死）；隐元数按经验/试凑。**批 vs 序贯**：批稳定、序贯（online）可逃离浅坑。**η 自适应**：震荡减半、下降缓慢则增大。

5.8 误差曲面与收敛性【概念】

单层线性网（LMS）：误差曲面是 w 的**二次碗形（凸）** ⇒ 唯一全局极小，梯度下降必收敛（η 小）；多层 sigmoid：误差曲面**非凸** ⇒ 局部极小/平台/鞍点，BP 收敛到**某个**局部极小，且**不保证**全局最优——对比题必写这一条。

推导 6 · SVM（最重点）

6.1 判别函数与距离【推导第一步】

$g(x)=w^Tx+b=0$；w = 法向量（面上任两点差 v 满足 $w^Tv=0$；b 只平移不改方向）。
点距（投影推导）：$dist(x_0)=|w^Tx_0+b|/\|w\|$

6.2 最大间隔四步【默写】

①线性分类器有**无穷多个**→选泛化最好的 = 最大 margin（对 outlier 鲁棒）；标签 $y_i\in\{-1,+1\}$，正确 ⇔ $y_i(w^Tx_i+b)\ge 0$
②w,b 同比缩放不改变平面 ⇒ 取缩放使**最近样本** $|w^Tx_i+b|=1$
③边界 $w^Tx+b=\pm1$ ⇒ $margin=2/\|w\|$
④max $2/\|w\|$ ⇔ **凸 QP**：$min\ \frac{1}{2}\|w\|^2\ s.t.\ y_i(w^Tx_i+b)\ge1,\ \forall i$

6.3 拉格朗日→对偶【默写】

$L=\frac{1}{2}\|w\|^2-\Sigma_i\alpha_i[y_i(w^Tx_i+b)-1]$，$\alpha_i\ge0$；
$\partial L/\partial w=0 \Rightarrow w=\Sigma_i\alpha_i y_i x_i$；$\partial L/\partial b=0 \Rightarrow \Sigma_i\alpha_i y_i=0$；代入 ⇒
$max_\alpha\ \Sigma_i\alpha_i-\frac{1}{2}\Sigma_i\Sigma_j\alpha_i\alpha_j y_i y_j x_i^T x_j\ \ s.t.\ \Sigma\alpha_i y_i=0,\ \alpha_i\ge0$

6.4 KKT 与支持向量【概念 + 推导】

$\alpha_i[y_i(w^Tx_i+b)-1]=0$：margin 上点 $\alpha_i>0$ = **SV**（唯一决定平面）；面外 $\alpha_i=0$（删之无影响）。
$g(x)=\Sigma_i\alpha_i y_i(x_i^Tx)+b$ —— 训练/判别**只用内积** ⇒ 核技巧前提。

6.5 软间隔【默写】

不可分/噪声：松弛 $\xi_i\ge0$：
$min\ \frac{1}{2}\|w\|^2+C\Sigma\xi_i\ s.t.\ y_i(w^Tx_i+b)\ge1-\xi_i,\ \xi_i\ge0$
对偶仅加箱 $0\le\alpha_i\le C$。**C 大→重罚误分类（易过拟合）；C 小→重间隔**。0<α<C 在面上；α=C 在带内/越界。

6.6 核技巧 + Mercer【默写】

Φ:x→φ(x) 高维可分；只需内积 ⇒ $K(x_i,x_j)=\varphi(x_i)^T\varphi(x_j)$，$g(x)=\Sigma\alpha_i y_i K(x_i,x)+b$，无需显式 φ。
Mercer：对称半正定（Gram 阵 PSD）⇔ 合法核。

6.7 常用核【必背】

核	公式
线性	$K=x_i^Tx$
多项式	$K=(1+x_i^Tx)^p$（一般式 $(\gamma x_i^Tx+r)^d$）
高斯 RBF	$K=exp(-\|x_i-x_j\|^2/(2\sigma^2))$
Sigmoid	$K=tanh(\beta\cdot x_i^Tx-b)$

核验证例题：$(1+x_i^Tx_j)^2=\varphi_i^T\varphi_j$，$\varphi(x)=[1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$（逐项展开对照）。

6.8 流程与设计【概念】

①选核 ②选 C ③解 QP ④由 SV 构 g(x)。σ 取不同类最近点距离量级；无准则→验证集/交叉验证；hard/soft 靠实验。SVM = **结构风险最小化**（Vapnik，90s初），仅依赖 SV ⇒ **小样本优于深度学习**、抗过拟合泛化强。

6.9 SVR【推导】

ε-不敏感管道（$|y-f|\le\varepsilon$ 不计损失）：
$min\ \frac{1}{2}\|w\|^2+C\Sigma(\xi_i+\xi_i^*)$ s.t. $y_i-w^T\varphi(x_i)-b\le\varepsilon+\xi_i$；
$w^T\varphi(x_i)+b-y_i\le\varepsilon+\xi_i^*$；$\xi,\xi^*\ge0$
解 $f(x)=\Sigma(\alpha_i-\alpha_i^*)K(x_i,x)+b$

6.10 LS-SVM【推导 + 对比】

Suykens & Vandewalle（KU Leuven, 1999）：不等式→**等式约束** + 平方误差：
$min\ \frac{1}{2}\|w\|^2+(\gamma/2)\Sigma e_i^2\ s.t.\ y_i=w^T\varphi(x_i)+b+e_i$
KKT ⇒ **线性方程组**：快；代价 = α 多非零，**失稀疏性**。应用：双螺旋分类、电力负荷预测。

6.11 软间隔对偶与求 b【推导细节】

软间隔对偶：$max\ \Sigma\alpha_i-\frac{1}{2}\Sigma_i\Sigma_j\alpha_i\alpha_j y_i y_j x_i^Tx_j$ s.t. $\Sigma\alpha_i y_i=0$, $\boldsymbol{0\le\alpha_i\le C}$（比硬间隔仅多箱约束）。
求 b：任取 SV（$0<\alpha_i<C$）代入 $y_i(w^Tx_i+b)=1$ ⇒ $b=y_i-\Sigma_j\alpha_j y_j x_j^Tx_i$；多 SV 取平均更稳。

6.12 SVM 解题自查【得分点】

①dist=|wᵀx+b|/‖w‖ ②margin=2/‖w‖ ③缩放使最近点=±1 ④$min\ \frac{1}{2}\|w\|^2\ s.t.\ y_i(w^Tx_i+b)\ge1$ ⑤写 L、∂L/∂w=0、∂L/∂b=0 ⑥对偶式含全约束 ⑦KKT 点明 SV ⑧核替换 $K=\varphi_i^T\varphi_j$ ⑨结论句（最大间隔/稀疏/泛化）。漏步 = 漏分。

6.13 学习规则横向【对比】

规则	Δw	监督	目标/备注
感知机	$\eta(d-y)x$	有	误分类驱动，**非梯度**
LMS/Delta	$\eta(d-w^Tx)x$	有	min MSE，梯度下降
BP 广义Delta	$\eta\delta_i z_j$	有	δ 含 σ′，逐层回传
Hebbian	$\eta\cdot y\cdot x$	无	同兴奋，须归一化防爆
竞争学习	$\eta(x-w^*)$	无	仅赢家权重向输入移动

6.14 人物—贡献速查【概念】

人物	机构/年份	贡献
McCulloch & Pitts	1943	M-P 阈值神经元
Hebb	1949	Hebb 规则（同兴奋）
Rosenblatt	Cornell, 50s末	感知机 + 收敛定理
Widrow & Hoff	Stanford, 60s初	ADALINE / LMS
Cover	1965	高维更可分定理
Grossberg	Boston U., 70s	ART1、竞争学习、两难
Kohonen	70s	SOM / 竞争学习代表
Werbos	1974	BP 首提
PDP 小组	1986	推广 BP（广义 delta）
Broomhead & Lowe	1988	RBF 网络
Pao	CWRU, 80s末	FLN 高阶聚合
Vapnik 等	90s初	SVM / 结构风险最小化
Suykens & Vandewalle	KU Leuven, 1999	LS-SVM
黄广斌 Huang	NTU, 00s中	ELM 极端学习机
Hopfield & Hinton	2024	诺贝尔物理学奖

零散考点【概念】：ADALINE 全称 Adaptive Linear **Elements**；LMS 又称 Delta/Widrow-Hoff 规则；BP 又称广义 delta 规则；MLP = 全局逼近、RBF = 局部逼近；SVM 判别只依赖 SV（删 α=0 样本结果不变）；核矩阵 = Gram 矩阵 $K_{ij}=K(x_i,x_j)$；MAXNET 常作 WTA 输出层。

概念 7 · 无监督与竞争学习

无监督：无标签学结构（聚类：按相似度分组，**主观无唯一解**）。**强化学习（课件口径）**：输入刺激强化权重/阈值以增强期望输出再现，例 **Hebbian**。**竞争学习**：单元竞争产出权（例 **Kohonen**）。

算法：X={x¹..xᵖ} 归 K 簇：①随机初始化 ②随机取 x_j 算 $w_i{}^T x_j$ ③选 $w^*=argmax$ ④只更新赢家 $w(t+1)=w(t)+\eta(x_j-w(t))$（可再归一化）⑤重复至收敛。
能量函数：$E=\Sigma_p\|x_p-w(x_p)\|^2$（样本到赢家权重距离平方和），学习使之下降。

概念 8 · MAXNET 与 kWTA

MAXNET：选最大输入的子网络（WTA），靠**相互抑制**保最大压其余；**循环**网络；**自兴奋权重=1，侧抑制权重=−w，w<1/m**（m = 单元数）；动力学 $x_j(t+1)=f(x_j(t)-w\Sigma_{i\neq j}x_i(t))$；常作输出层。
kWTA：选前 **k** 大响应、抑制其余；Heaviside 激活（σ(s)=1 if s>0 else 0）版**全局稳定、有限时间收敛**到 kWTA 解（有收敛时间上下界）。

对比 9 · 网络对比大题（期中占 25%）

T1 Perceptron vs ADALINE【课件原句必背】

	Perceptron	ADALINE
激活	hard-limit（双/单极）	线性（学习时）
规则	误分类驱动，**非梯度**	LMS/Delta，**梯度下降**
模式	序贯或 batch	**仅 batch**
目标	分类正确即停	min MSE
XOR	✗	✗

Architecture: Perceptron uses a bipolar or unipolar hardlimiter activation function, Adaline uses a linear activation function. Learning rule: the perceptron learning algorithm is not gradient-descent and can operate in either sequential or batch training mode, whereas the Adaline learning (LMS) algorithm is gradient descent, but can only operate in batch mode.

T2 五模型横向

	单层感知机	MLP+BP	RBF	SVM
结构	单层前馈	多层前馈	两层前馈	前馈+核
学习	有监督·误差驱动	有监督·梯度递归	两阶段(中心/线性读出)	有监督·QP对偶
激活	hard-limit	sigmoid×2	高斯+线性	核内积
XOR	✗	✓	✓	✓(核)
局部极小	—	可能有	无(LS解)	无(凸QP)
弱点	仅线性可分	慢/极小/过拟合	维度灾难/选中心	选核与C/大规模慢

T3 MLP vs RBF

隐层：sigmoid**全局** vs 高斯**局部**（近中心才激活）｜输出层：均线性｜训练：全网络迭代梯度 vs 两阶段（中心+输出**最小二乘一步解**）｜局部极小：可有 vs 输出层无｜速度：RBF 通常快｜表述：**RBF 是结构，BP 是算法。**

T4 SVM vs SVR vs LS-SVM

SVR：ε-不敏感损失、不等式约束、QP、**稀疏**｜LS-SVM：等式约束 + 平方误差→**线性方程组**、快、**非稀疏**｜同：结构风险最小化、可核化。

T5 竞争学习 vs MAXNET vs kWTA

竞争学习 = **学习范式**（赢家权重向输入移动成簇）；MAXNET = 实现 WTA 的**循环子网络**（1/−w<1/m），常作输出层；kWTA = 前 k 赢家（Heaviside 版全局稳定、有限时间收敛）。

T6 结构与范式辨析

前馈 vs 循环 = 信号流向（循环例：MAXNET；ART1、Hopfield 属期末）；**BP 是算法非结构**，误差反传≠循环连接；**有监督**（P/ADALINE/BP/SVM）vs **无监督**（竞争学习/聚类）；短/长期记忆 = u,v / w。

T7 Hebbian vs 竞争学习 vs Delta【范式】

Hebbian：Δw=η·d·x 或 ηyx（同兴奋，无教师信号方向校正，权重无界增长需归一化）｜**竞争学习**：仅赢家 w←w+η(x−w)（无监督、聚类、权重向输入移动）｜**Delta/LMS**：Δw=η(d−y)x（有监督、误差驱动、降 MSE）。共同点 = 都是增量规则 w(t+1)=w(t)+η·r 的特例。

公式补遗【推导速查】

范数/距离：$\|w\|=\sqrt{(\Sigma w_i^2)}$；margin=2/‖w‖；点距 $|w^Tx+b|/\|w\|$；高斯基 $\exp(-\|x-c\|^2/(2\sigma^2))$。
梯度对照：LMS $\nabla E=-\Sigma_p e_p x_p \Rightarrow w+=\eta\Sigma_p e_p x_p$ ｜ BP 输出 $\delta_k=(d_k-y_k)y_k(1-y_k)$ ｜ 隐层 $\delta_j=z_j(1-z_j)\Sigma_k w_{jk}\delta_k$ ｜ SVM 对偶 $\max \Sigma\alpha-½\Sigma\Sigma\alpha_i\alpha_j y_i y_j K_{ij}$。
约束形式对照：硬间隔 $y_i(w^Tx_i+b)\geq 1$ ｜ 软间隔 $\geq 1-\xi_i,\ \xi_i\geq 0$ ｜ SVR 双不等式 $\leq\varepsilon+\xi$ ｜ LS-SVM 等式 $y=w^T\varphi+b+e$。
目标函数对照：LMS/BP ½Σ(d−y)² ｜ SVM ½‖w‖²(+CΣξ) ｜ LS-SVM ½‖w‖²+(γ/2)Σe² ｜ 竞争 Σ‖x−w(x)‖²。

易错公式急救【弱项】

①margin 分母是 ‖w‖**一次方**，距离公式分母也是 ‖w‖；②软间隔约束右边是 **1−ξ** 不是 1+ξ；③对偶目标是 **max** Σα−½…（别写成 min）；④SVM 判别式含 $\mathbf{y_i}$：$g=\Sigma\alpha_i y_i K(x_i,x)+b$；⑤隐层 δ 无 d、须乘 **自身导数**；⑥MAXNET 侧抑制 w<1/m 且自兴奋=**1**；⑦σ′(单极)=y(1−y)、σ′(双极)=**1−y²** 别混。

英语 10 · 生僻学术英语速查表（按首字母）

Term	中文对照	Term	中文对照
A absolute linearly separable	绝对线性可分	activation / aggregation rule	激活 / 聚合规则
adaptive resonance	自适应共振	arbitrary (any) logic function	任意逻辑函数
B backpropagation	反向传播（误差回传）	batch / sequential mode	批量 / 序贯（逐样本）模式
bias (threshold θ)	偏置（阈值）	bipolar / unipolar	双极 {−1,+1} / 单极 {0,1}
bottom-up / top-down	自下而上 / 自上而下	boundary (decision ~)	（决策）边界 ≙拼 boundary
C catastrophic forgetting	灾难性遗忘	competitive learning	竞争学习
complementary slackness	互补松弛（KKT）	convergence (in finite steps)	收敛（有限步内）
convex QP / concave	凸二次规划 / 凹	Cover's theorem	Cover 定理（高维更可分）
D delta rule (generalized)	（广义）Delta 规则	discriminant function	判别函数
dual / primal problem	对偶 / 原始问题	dimensionality curse	维数灾难
E energy function	能量函数	epoch / iteration	轮 / 迭代
evaluation rule (E)	评价规则（误差/能量）	explicit mapping	显式映射 φ
F feature space / φ-separable	特征空间 / 特征可分	feedforward / recurrent	前馈 / 循环
finite automaton	有限自动机	flexibility (plasticity)	可塑性
G Gaussian (RBF)	高斯（径向基）	generalization	泛化
gradient descent	梯度下降	Gram matrix	格拉姆矩阵（核矩阵）
H hard limiter	硬限幅器（阶跃）	Hebbian rule	赫布规则
hidden layer	隐层	higher-order aggregation	高阶聚合
hyperplane	超平面	hypothesis (class)	假设（类）
I incremental learning	增量学习	inner product	内积
interconnection weight	互连权重	invariant (to scaling)	（对缩放）不变
K kernel trick / function	核技巧 / 核函数	kernel width σ	核宽度
k-winners-take-all	k-胜者全得	Kolmogorov theorem	柯尔莫哥洛夫定理
L Lagrangian multiplier α	拉格朗日乘子	learnability	可学习性
learning rate η	学习率（步长）	linearly separable	线性可分
local minimum	局部极小	long/short-term memory	长/短期记忆（w / u,v）
M margin (maximal ~)	间隔（最大间隔）	mean squared error	均方误差 MSE
Mercer's theorem	Mercer 定理（半正定）	misclassification	误分类
momentum (term)	动量（项）	monotonic	单调（函数/逻辑）
N neuron / unit	神经元 / 单元	nonlinearly separable	非线性可分
normal vector	法向量	normalization	归一化
O objective function	目标函数	outlier	离群点/异常样本
output layer	输出层	overfitting	过拟合
P perceptron	感知机	pattern / sample	模式 / 样本
penalty factor C	惩罚因子	plateau	平台（平坦区）
projection	投影	quadratic programming	二次规划 QP
R radial basis function	径向基函数 RBF	reinforcement learning	强化学习（课件口径）
resonance	共振（匹配成功）	robustness	鲁棒性
S semi-positive definite	半正定	slack variable ξ	松弛变量
sparsity / sparse	稀疏性 / 稀疏的	stability-plasticity dilemma	稳定性—可塑性两难
structural risk	结构风险	supervised / unsupervised	有监督 / 无监督
support vector (SV)	支持向量	symmetric breaking	对称破缺（初始化）
T template (top-down t)	模板（自上而下权）	threshold θ	阈值
tolerance	容差（警戒相似度）	training mode	训练模式
U universal approximator	通用逼近器	update rule	更新规则
V vigilance (parameter ρ)	警戒（参数）	violation (constraint)	（约束）违反
W weight space	权重空间	winner-take-all	胜者全得 WTA
X XOR (exclusive-or)	异或（非线性可分）	zero-error region	零误差区

英文答题句【背诵】

- A dataset is linearly separable if a linear decision boundary can classify all samples correctly.
- The hidden-layer delta sums the error contributions of all output neurons it feeds, weighted by the connecting weights.
- An RBF network has a Gaussian hidden layer and a linear output layer; inputs become linearly separable in the feature space (Cover's theorem).
- Support vectors are the samples on the margin ($\alpha_i>0$); they alone determine the optimal hyperplane.
- The kernel trick computes inner products in a high-dimensional feature space without the explicit mapping: $K(x,z)=\varphi(x)^T\varphi(z)$.
- C trades off margin maximization versus violation penalty: large C → fewer violations, small C → wider margin.
- MLPs are universal approximators, but BP is not guaranteed to find the optimal weights (local minima).

对比 11 · 对比题答题骨架 + 加分句

骨架（五要素）：①**结构**（层/前馈·循环/激活）→②**学习规则**（谁更新、公式、监督否）→③**优化目标**（min MSE / max margin / 聚类误差）→④**性质**（收敛条件/局部极小/稀疏性/XOR）→⑤**适用与弱点**。每对比至少写 4 要素，用完整句 + whereas。
加分句：The key difference lies in the objective: ADALINE minimizes the MSE of the linear output, whereas the perceptron only corrects misclassifications. ｜ SVM maximizes the margin subject to constraints, which yields a convex problem without local minima. ｜ RBF networks transform the input into a higher-dimensional feature space where linear separation is more likely (Cover).

概念 12 · 选择/填空陷阱清单【弱项】

①M-P：抑制输入为 1 ⇒ 输出**必 0**（不是看加权和）；②两层 M-P = 任意逻辑函数；无抑制 = **单调**函数；③收敛定理前提线性可分、有限步、得 w**和**θ；④XOR 原因非线性可分（不是权不够）；⑤ADALINE 仅 batch、误差来自线性输出；⑥$\nabla E=-\Sigma e_p x_p$（符号别反）；⑦σ′(单极)=y(1−y)，σ′(双极)=1−y²；⑧隐层 δ 无 d；⑨MLP 逼近存在但 BP 不保证；⑩Cover 是"更可能"非"必然"；⑪KKT：α>0⇔在 margin 上；⑫C 大重罚误分类；⑬Mercer = 对称半正定；⑭LS-SVM 失稀疏；⑮MAXNET：自兴奋 1、侧抑制 −w<1/m；⑯kWTA Heaviside 版全局稳定有限时间；⑰样本 4 面→最多 **14** 区（非 16）；⑱Hopfield、ART1 属期末范围，别写进期中对比。

概念 13 · 参数效应速查【推导追问常考】

参数	增大时	减小时
η 学习率	快但震荡/发散	稳但极慢
α 动量	惯性大、易冲过头	接近无动量
C 惩罚	重罚违反、间隔窄、易过拟合	重间隔、容违反、平滑
σ 高斯核宽	核平滑、欠拟合（过远都相似）	核尖锐、过拟合（只认近邻）
γ LS-SVM	重拟合误差 e	重 ‖w‖² 正则

SVM 细节补遗：$\alpha_i=0$ 样本可删；$0<\alpha_i<C$ 恰在 margin 上；$\alpha_i=C$ 在 margin 内或误分类（ξ>0）；b 由 SV 的 $y_i(w^Tx_i+b)=1$ 解出；核化后判别只用 K 与 SV，无需显式 φ。

概念 14 · 常见设问英译→答题指向

设问（英文常见措辞）	答什么（指向）
State the perceptron convergence theorem	§2.3 三要素全写
Why can a single-layer perceptron not solve XOR	急救卡②：not linearly separable
Derive the LMS / delta rule	§3 四步①E ②∇E ③下降 ④更新
Derive the update rule for hidden units in BP	§4.3 ③$\delta_j=z_j(1-z_j)\Sigma_k w_{jk}\delta_k$
Show that the margin equals 2/‖w‖	§6.2 ②③缩放 + 两边界距离
Formulate the dual of the SVM	§6.3 L→偏导→代入→对偶式
What are support vectors / their role	§6.4 KKT：α>0 在 margin，唯一一定平面
Explain the kernel trick / Mercer's condition	§6.6 内积替代 + 对称半正定
Compare A and B (differences)	§11 五要素骨架 + whereas 完整句
Is BP a network architecture?	否 = 学习算法；recurrent 与否是结构问题