

课程讲解聚类与高斯混合模型。作业 1 占 15 分，截止 9 月 30 日 23:59；K-means 对初始化敏感且仅适用球形簇；GMM 通过 EM 算法迭代估计软归属与参数，需防过拟合，可用 BIC 选 K。课后进入答疑，讨论作业要求及 K-means 一维数据练习，未涉及新业务决定。

Assignment One 作业安排与要求

- **作业基本信息**
  - Assignment One 已在 Canvas 平台发布，路径为 Assignments → Assignment One
  - 该作业占总成绩 15 分，共两次作业合计占 15-20 分
  - 截止时间为 9 月 30 日 11:59，逾期将导致最终成绩上限降至 85 分
- **缺课同学通知**
  - 讲师请到场同学转告未出席者作业发布信息及截止时间
  - 强调缺课可能错过 15 分作业，影响最终成绩

K-means 算法原理与局限性

- **算法核心机制**
  - 目标是最小化簇内平方误差和（within-cluster variation），而非最大化簇间距离
  - 迭代执行两步：固定中心更新分配（assign to nearest centroid），固定分配更新中心（mean of assigned points）
  - 使用指示变量 r_{ik} 将离散分配转化为数学优化形式，$r_{ik} = 1$ 表示点 i 属于簇 k
- **收敛性与初始化敏感性**
  - 每步迭代目标函数不增，因分配数和状态有限，算法必收敛到不动点
  - 收敛结果仅为局部最优，不同初始化可导致不同最终聚类
  - 改进策略包括多次运行取最优、K-means++ 初始化（优先选远离已选中心的点）
- **典型失败场景**
  - **长条形或平行簇**：欧氏距离假设球形簇，无法正确分离平行长条结构，除非初始化恰好落在各条中心
  - **密度差异大**：低密度簇的点可能被高密度簇的均值吸引，导致错误合并
  - **非凸形状**：如环形或月牙形数据，均值不是有意义的中心，K-means 会将其切割为不合理部分
  - **异常值影响**：单个极端点可显著拉偏簇中心，导致孤立点自成簇或扭曲整体结构

高斯混合模型与 EM 算法

- **GMM 模型定义**
  - 每个观测由 K 个高斯分量之一生成，隐变量 $z_i \in \{1, ..., K\}$ 表示来源分量
  - 三组参数：混合权重 π_k（$\sum \pi_k = 1$）、均值 μ_k、协方差矩阵 Σ_k
  - 边缘概率 $p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$，允许软分配与椭球簇形
- **EM 算法流程**
  - **E 步**：固定当前参数，计算责任度 $\gamma_{ik} = p(z_i = k \mid x_i)$，即点 i 来自分量 k 的后验概率
  - **M 步**：固定责任度，更新参数：
    - 有效样本数 $N_k = \sum_i \gamma_{ik}$（可为非整数）
    - 新权重 $\pi_k^{new} = N_k / N$
    - 新均值 $\mu_k^{new} = \frac{1}{N_k} \sum_i \gamma_{ik} x_i$
    - 新协方差 $\Sigma_k^{new} = \frac{1}{N_k} \sum_i \gamma_{ik} (x_i - \mu_k^{new})(x_i - \mu_k^{new})^T$
  - 数值示例：三点 {1,3,5}，两分量，初始 $\mu = \{1, 5\}, \sigma^2 = 1, \pi = 0.5$；第一轮后 μ 更新为 {1.66, 4.33}，因中间点 3 对两分量贡献均等
- **为何使用 EM 而非直接 MLE**
  - 对数似然含 $\log \sum$ 形式，无法解析求解
  - EM 引入辅助分布 $q(z)$，利用 Jensen 不等式构造下界 $\mathcal{L}(q, \theta) \leq \log p(X \mid \theta)$
  - E 步使下界紧贴真实似然（令 $q(z) = p(z \mid X, \theta)$），M 步最大化下界以提升似然
  - 下界与真实似然的差距等于 KL 散度 $KL(q \,||\, p)$，非负且仅在 $q = p$ 时为零

协方差结构选择与模型评估

- **四种协方差约束类型**
  - **Spherical**：$\Sigma_k = \sigma_k^2 I$，各向同性，等价于 K-means 的球形假设
  - **Diagonal**：Σ_k 为对角阵，各特征独立但方差可不同，轴对齐椭球
  - **Shared**：所有分量共享同一 Σ，形状相同但中心不同
  - **Full**：无约束，每个分量有完整协方差矩阵，最灵活但参数最多
- **过拟合风险与防护**
  - 当某分量坍缩到单点且 $\sigma_k^2 \to 0$ 时，似然趋于无穷，模型记忆噪声而非学习结构
  - 防护措施：设置最小有效样本数（如 $N_k \geq 5$ 或 10）、方差下限正则化、多次初始化、验证集评估
- **模型选择准则**
  - BIC（Bayesian Information Criterion）：$BIC = -2 \log L + d \log N$，其中 d 为参数总数，N 为样本数
  - BIC 越低表示模型在拟合优度与复杂度间平衡更好，可用于选择分量数 K
  - 注意：GMM 分量不等于真实类别，一个真实类可能需要多个分量建模，需结合领域知识解读

高光谱图像聚类应用案例

- **数据特性与挑战**
  - 高光谱图像每个像素含数百波段（400–2500 nm，间隔约 5 nm），形成高维光谱向量
  - 挑战包括波段高度相关、同物异谱（如土壤颜色随湿度变化）、邻域空间上下文重要
- **处理方法与基线效果**
  - 常用流程：先降维或特征提取，再聚类；或使用超像素分割构建图，进行标签传播
  - 讲师研究中以 K-means 和 GMM 作为基线，在某数据集上 K-means 准确率超过 75%
  - 尽管简单，K-means 仍可作为有效起点，尤其配合预处理（如 PCA、超像素）时表现稳健