

机器学习课讲解核密度估计、均值漂移及谱聚类原理，对比各算法优劣与计算成本；课堂练习 KDE 带宽选择及迭代计算。考务方面：首次作业占总分 15%，截止后天；期中考允许带一张 A4 纸作弊条，计算器不限型号；期末考计算器需符合批准清单。讲师提醒目前作业提交率低且出勤不足七成，强调按时交作业以免影响成绩，课后将上传习题解答。

考试政策与学业提醒

- **考试形式与携带物品规定**
  - **半开卷考试政策**：考试性质为半开卷（half open book），允许每位学生携带一张 A4 纸作为笔记（cheat sheet），可使用正反两面，内容不限，支持手写或打印（如使用 Word 缩小排版）
  - **计算器使用规范**
    - Midterm 考试对计算器型号无限制，学生可携带任意计算器
    - Final 考试必须使用学院批准的计算器列表中的型号，列表包含约 20 款设备，讲者将在 Canvas 公告中提供链接
    - 讲者建议学生购买便宜型号或在二手平台购置以节省开支，City University 新生曾花费约 500 元购买
- **作业与出勤要求**
  - **作业 1 权重与截止时间**：第一次作业占总成绩的 15%，截止日期为后天晚上；目前仅收到 14 份提交，而选课人数约 60 人，讲者对提交进度表示担忧
  - **出勤率预警**：部分学生出勤率低于 70%，讲者收到邮件提示此问题，但不确定学院将如何处理，强调出勤虽不计分但对学习至关重要，缺勤需请假或告知
- **复习范围与资料获取**
  - **重点复习内容**：考试范围主要覆盖前三周课程内容，特别是五种概率分布（Song distribution、Normal distribution、Poisson distribution、Bernoulli distribution、Flashing distribution）的性质与应用
  - **课件与习题解答**：所有课程材料及习题解答（solution）均已上传至 Canvas 对应文件夹，讲者提醒学生自行查阅，包括本次课程的额外讲义

局部密度估计原理与直方图局限

- **从参数模型到局部方法的过渡**

- **参数模型的局限性**：参数模型（如泊松模型、高斯混合模型）假设数据服从特定分布族，仅通过调整参数拟合数据，灵活性受限于预设的模型结构
- **局部估计的核心思想**：局部方法不预设全局分布，而是基于目标点邻域内的观测数据进行估计，邻域由半径 R 定义，满足距离≤R 的点被视为邻居

· **一维局部样本分数估计**
- **矩形近似推导**：当区间[x-R, x+R]足够小时，密度函数 p(x)在该区间内近似恒定，概率质量可近似为矩形面积 2R·p(x)
- **密度估计公式**：令 NR(x)为落入区间的样本数，则经验概率为 NR(x)/n，联立得密度估计$\hat{p}(x) = \frac{N_R(x)}{2nR}$，即局部样本分数除以局部体积

· **直方图作为局部估计的特例与缺陷**
- **直方图与局部估计的关系**：直方图本质是局部样本分数估计的应用，bin 宽度 h 对应 2R，密度估计为 bin 内样本数除以(n·h)
- **直方图的两大局限**
  - **不连续性**：bin 边界处密度估计存在跳跃，无法反映真实密度的连续变化
  - **网格敏感性**：即使 h 相同，改变 bin 的起始位置会导致不同的计数结果，进而产生不同的直方图形态，估计结果不稳定

核密度估计 KDE 详解

· **KDE 的定义与核函数作用**
- **KDE 基本公式**：每个观测点 xi 贡献一个核函数$K_h(x - x_i)$，整体密度估计为所有贡献的平均$\hat{p}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K(\frac{x-x_i}{h})$，保证估计结果连续且积分为 1
- **核函数的选择与特性**
  - **高斯核（Gaussian Kernel）**：最常用的核函数，形式为$\frac{1}{\sqrt{2\pi}} e^{-u^2/2}$，提供平滑的贡献曲线
  - **Box 核**：在[−1,1]区间内值为 1/2，否则为 0，等价于均匀分布，其 KDE 退化为移动窗口的局部计数
  - **核函数的影响**：核函数决定局部贡献的形状，但对估计结果的影响通常小于带宽 h 的选择

· **带宽 h 的作用与选择策略**
- **带宽对估计形态的控制**
  - **小带宽**：每个核贡献窄而高，保留更多细节但噪声大，可能出现零密度间隙（如 h=1 时在 x=1 处密度为 0）
  - **大带宽**：每个核贡献宽而低，平滑度高但丢失细节，可能掩盖真实分布结构
  - **面积守恒**：改变 h 时，核函数通过 1/h 缩放保持高度与宽度的平衡，确保单个观测的总概率质量始终为 1
- **带宽选择的实践方法**
  - **验证集选择**：不能使用训练集选择 h，因为 h→0 时训练点自身贡献趋于无穷大，导致过拟合；应使用验证集或交叉验证，最大化验证数据的似然或最小化损失
  - **候选值评估**：选取多个 h 候选值，分别计算验证集上的性能指标，选择最优者

· **多维 KDE 与特征归一化**
- **多维 KDE 公式**：d 维空间中，体积因子变为h^d，估计式为$\hat{p}_h(x) = \frac{1}{nh^d} \sum_{i=1}^{n} K(\frac{x-x_i}{h})$，常用乘积核假设各维度独立
- **归一化的必要性**：不同特征量纲差异大（如年龄 21-23 岁 vs 体重 40-100kg）会导致距离计算被大量纲特征主导，必须先将所有特征缩放到相同范围（如[0,1]）以满足各维度方差相等的隐含假设

· **KDE 的理论性质与计算考量**

- **偏差-方差权衡**：小 h 导致低平滑偏差但高方差（估计波动大），大 h 导致高平滑偏差但低方差（估计过于平滑），最优 h 需平衡二者
- **样本量的影响**：增加样本量 n 可减少估计的随机波动，使局部估计更可靠；但 h 的选择仍需随 n 调整
- **维度灾难**：随着维度 d 增加，固定 h 下的局部体积h^d急剧缩小，导致邻域内样本稀疏，需要指数级增长的样本量才能维持估计精度
- **实现注意事项**
  - 特征必须归一化
  - 核函数可能在有效范围外赋值（如高斯核在负值区域），需处理边界问题
  - 数值稳定性：避免极小正数导致的计算溢出

均值漂移聚类算法

- **算法原理与梯度上升视角**
  - **密度峰值作为聚类中心**：聚类中心对应密度函数的局部极大值点，均值漂移通过梯度上升寻找这些峰值，无需预先指定聚类数量 K
  - **梯度推导与位移向量**：对高斯核 KDE 求梯度，可得位移向量$m(x) = \frac{\sum_i w_i(x) x_i}{\sum_i w_i(x)} - x$，其中权重$w_i(x) = k'(\| \frac{x - x_i}{h} \|^2)$，新位置$x_{new} = x + m(x)$即为加权局部均值
- **迭代过程与收敛特性**
  - **迭代步骤**：从初始点 x0 出发，重复计算权重→更新位置→检查收敛，直到位移小于阈值或位置稳定
  - **收敛行为**：不同起始点可能收敛到同一峰值（形成同一簇），也可能收敛到不同峰值；收敛速度受 h 影响，h 越大收敛越快但分辨率越低
- **与 K-means 及 GMM 的对比**
  - **无需预设 K**：聚类数量由 h 和数据分布自然决定，小 h 产生多簇，大 h 合并为少簇
  - **软分配机制**：不同于 K-means 的硬分配，均值漂移使用软权重，类似 GMM 但无需假设高斯成分
  - **计算成本**：每次迭代需计算所有点到当前位置的距离，复杂度 O(n²d)，大数据集需采用近邻搜索或近似算法加速

谱聚类方法

- **图构建与相似度矩阵**
  - **图的定义**：每个数据点为节点，边权重 wij 表示相似度，常用高斯相似度$w_{ij} = e^{-\|x_i - x_j\|^2 / \sigma^2}$或 k 近邻连接
  - **关键参数**：邻居数量 k、相似度尺度 σ、最终聚类数 K（用于后续 K-means）；图构建决定了聚类的几何结构
- **拉普拉斯矩阵与归一化割**
  - **度矩阵与拉普拉斯矩阵**：度矩阵 D 为对角阵，$D_{ii} = \sum_j w_{ij}$；未归一化拉普拉斯 L = D - W，其二次型$f^T L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2$衡量图上函数的平滑度
  - **归一化割（Ncut）**：目标是最小化跨簇边权和同时平衡簇大小，定义为$Ncut(A, B) = \frac{cut(A,B)}{vol(A)} + \frac{cut(A,B)}{vol(B)}$，避免切出孤立小簇
- **特征向量嵌入与聚类**
  - **松弛优化**：Ncut 的最小化是 NP 难问题，松弛为求解广义特征问题$Lf = \lambda D f$，取前 k 个最小非零特征值对应的特征向量作为新特征
  - **谱空间聚类**：在新特征空间（谱嵌入）中使用 K-means 等传统方法聚类，此时欧氏距离反映了图连通性而非原始几何距离
- **计算复杂度与近似方法**

- **精确计算代价**：构建全连接图需 $O(n^2)$相似度计算，特征分解需 $O(n^3)$，难以扩展到大样本
- **加速策略**：使用 k 近邻图代替全连接图、树结构近似近邻搜索、稀疏特征值求解器（如 Lanczos 算法）降低计算负担

四种聚类方法对比总结

- **聚类定义的差异**
  - **K-means**：簇内点到质心距离最小化，假设簇为凸球形
  - **GMM**：数据由多个高斯成分生成，簇为概率等值面
  - **均值漂移**：簇为密度峰值的吸引域，形状由密度地形决定
  - **谱聚类**：簇为图上强连通子图，可捕获非凸、流形结构
- **假设与适用场景**
  - **K-means**：假设簇大小相近、球形分布，对初始化敏感，计算高效 O(nkd)
  - **GMM**：假设数据可由高斯混合生成，提供软分配和概率输出，但对非高斯结构失效
  - **均值漂移**：无需参数化假设，适合任意形状簇，但计算成本高 $O(n^2d)$且 h 选择关键
  - **谱聚类**：依赖图构建质量，适合复杂流形结构，但计算最昂贵且需指定 K
- **共同挑战与发展方向**
  - **局部 vs 全局**：从全局模型（K-means/GMM）到局部结构（均值漂移/谱聚类）的演进，反映了对数据内在几何的重视
  - **超参数敏感性**：所有方法均依赖关键超参数（K/h/σ/k），选择不当导致性能骤降
  - **计算效率**：机器学习发展强调在保持性能的同时降低计算成本，推动近似算法和高效实现的研究

课堂练习与答疑要点

- **KDE 数值计算练习**
  - **题目设定**：数据点{0,2,3}，使用三角核$K(u) = max(0, 1 - \mid u \mid)$，计算 x=2 处在 h=1 和 h=2 时的密度估计
  - **计算结果**：h=1 时，仅 x=2 自身贡献，$\hat{p}(2) = 1/3$；h=2 时，三点均有贡献，$\hat{p}(2) = 1/4$
  - **验证集选择演示**：验证点 x=1，h=1 时密度为 0，h=2 时密度为 1/6，故 h=2 更优，体现大带宽在稀疏区域的平滑优势
- **均值漂移迭代练习**
  - **题目设定**：数据点{0,1,2,3}，高斯核 h=1，起始点 x0=2
  - **迭代结果**：第一次更新 x1=1.355（左移 0.645），第二次 x2=0.778，持续向高密度区（0-1 附近）移动
- **谱聚类 Ncut 比较练习**
  - **题目设定**：给定权重矩阵 W，比较两种划分 P1={1,2}|{3,4}和 P2={1}|{2,3,4}的 Ncut 值
  - **计算结果**：P1 的 Ncut≈0.086，P2 的 Ncut≈1.273，因 Ncut 越小越好，故 P1 为优选划分，验证了归一化割对平衡簇大小的作用
- **学生答疑与资源指引**
  - **资料获取**：所有课件、习题解答均按课程模块存放于 Canvas 对应文件夹，学生需自行下载
  - **Cheat Sheet 制作建议**：可使用 Word 等工具压缩内容至 A4 双面，充分利用空间；讲者展示样例供参考
  - **后续安排**：国庆假期后复课，下次课时长 1-2 小时，将介绍分类器基础；鼓励学生利用课间或课后提问

待办事项

- @全体学生 提交作业 1（DDL：后天晚上）
- @全体学生 检查 Final 考试计算器是否在批准列表内（DDL：Final 考前）
- @全体学生 准备一张 A4 双面 Cheat Sheet（DDL：Midterm/Final 考前）
- @全体学生 复习前三周课程内容及五种概率分布（DDL：考前）
- @发言人 1 上传本次课程课件及习题解答至 Canvas 对应文件夹（DDL：课后）
- @发言人 1 在 Canvas 公告中发布 Final 考试计算器批准列表链接（DDL：近期）