① 五大分布（期望/方差）

分布	公式	E	Var
Bernoulli(π)	$\pi^x(1-\pi)^{1-x}$	π	π(1−π)
Binomial(n,π)	$C(n,k)\pi^k(1-\pi)^{n-k}$	np	np(1−π)
Poisson(λ)	$e^{-\lambda}\lambda^k/k!$	λ	λ
$N(\mu,\sigma^2)$	$(2\pi\sigma^2)^{-1/2}e^{-(x-\mu)^2/2\sigma^2}$	μ	σ^2
Beta(α,β)	$\propto\pi^{\alpha-1}(1-\pi)^{\beta-1}$	α/(α+β)	αβ/[(α+β)²(α+β+1)]

Beta(1,1)=均匀；五分布=考试重点。

② 贝叶斯 + 指标

$P(D|+)= P(+|D)P(D) / [P(+|D)P(D)+P(+|\neg D)P(\neg D)]$

医学例:

0.9×0.02/(0.9×0.02+0.08×0.98)=**0.187**；真阳 180 vs 假阳 784（基础率低⇒阳性多没病）。

敏感性 P(+|D) ≠ 后验 P(D|+)。

Acc=(TP+TN)/N（不平衡会骗人）；**精确率**=TP/(TP+FP)；**召回/敏感**=TP/(TP+FN)；特异=TN/(TN+FP)。训练→验证（选模型）→测试（只碰一次）；预处理只用训练集。

③ 期望/协方差规则

$Y=AX+b \Rightarrow E[Y]=A\mu+b$；$\Sigma_Y=A\Sigma A^T$（b 不影响 Σ）

$Y=a^TX+b \Rightarrow E=a^T\mu+b$；$Var=a^T\Sigma a$

例: A=[[1,1],[0,1]], Σ=diag(4,1) ⇒ Σ_Y=[[5,1],[1,1]]，E[Y]=A[1,0]+b

Cov=E[(X−E[X])(Y−E[Y])]；ρ=Cov/σσ ∈[−1,1] 无量纲

④ 多元高斯·马氏距离（模板）

$p(x)\propto\exp[-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)]$；同一高斯比两点⇒只比 $D=(x-\mu)^T\Sigma^{-1}(x-\mu)$，D 小者 p 大；$p_A/p_B=\exp[-\frac{1}{2}(D_A-D_B)]$

步骤：|Σ| → Σ^{-1} → 偏差 → D → 比较 → 比值。

2×2 逆：$[[a,b],[b,c]]^{-1} = (ac-b^2)^{-1}[[c,-b],[-b,a]]$

Q1: μ=[1,2], Σ=[[4,1],[1,1]]：|Σ|=3，$\Sigma^{-1}=\frac{1}{3}[[1,-1],[-1,4]]$；$x_A-\mu=[2,1] \Rightarrow D_A=4/3$；$x_B-\mu=[0,2] \Rightarrow D_B=16/3 \Rightarrow p_A>p_B$（欧氏距离同为√5）；比值=$e^2\approx7.39$

⑤ 特征值 / PCA / SVD

[[a,b],[b,a]] 型：λ=a±b，u=1/√2[1,±1]；一般 2×2 对称：$\lambda=[(a+c)\pm\sqrt{(a-c)^2+4b^2}]/2$

例: [[3,2],[2,3]] ⇒ λ=5,1；u_1=1/√2[1,1]（最大方差方向）

PCA 方向=协方差阵最大特征值的特征向量；中心化 $X=UDV^T$ ⇒ **V 列=PCA 方向**，大奇异值=大方差（$X^TX=VD^2V^T$）

⑥ MLE 万能四步

连乘似然 → 取 log → 导数=0 → 检查边界

Bernoulli: $\hat{\pi}=m/n$；全成功 ⇒ $\hat{\pi}=1$（边界，$L=\pi^n$ 单调）

高斯: $\hat{\mu}=\bar{x}$；$\sigma^2_{MLE}=(1/n)\Sigma(x_i-\bar{x})^2$；无偏版 ÷(n−1)（均值从数据估出，损失 1 自由度，MLE 偏小）

不等方差（Q6）: $\hat{\mu}=\Sigma(x_i/\sigma_i^2)/\Sigma(1/\sigma_i^2)$（精度加权）；$\sigma_i^2$ 相等 ⇒ $\bar{x}$

⑦ 回归数值题（列表法）

正规方程：$\Sigma r_i=0$，$\Sigma x_i r_i=0$ ⇒

$n\cdot w_0+w_1\Sigma x=\Sigma y$；$w_0\Sigma x+w_1\Sigma x^2=\Sigma xy$

Q2: (−1,0),(0,1),(1,2),(2,2)：Σx=2, Σy=5, Σxy=6, $\Sigma x^2=6$ ⇒ $4w_0+2w_1=5$；$2w_0+6w_1=6$ ⇒ **$w_0=0.9$, $w_1=0.7$**；残差=(−0.2,0.1,0.4,−0.3) ⇒ $\sigma^2=0.3/4=$**0.075**；$\hat{y}(3)=0.9+2.1=$**3.0**

套路：先填 x,y,xy,x^2 四列求和 → 解 2×2 方程 → 残差平方平均=σ^2 → 代入预测。

⑧ Beta-Bernoulli 更新

$\text{Beta}(\alpha,\beta)+(m,n-m) \Rightarrow \text{Beta}(\alpha+m,\beta+n-m)$

后验均值=下次成功概率=(α+m)/(α+β+n)；MAP=(α+m−1)/(α+β+n−2)（要求 α+m>1, β+n−m>1，否则边界）

例: B(2,2), m=3, n=4 ⇒ B(5,3)：均值 5/8=0.625，MAP 2/3≈0.667，MLE 0.75

（先验 $\kappa_0=\alpha+\beta$ 越大越拉向先验；B(20,20) 同数据⇒23/44≈0.523）

均值=加权平均：$w_{prior}(\alpha+\beta)/(\alpha+\beta+n)\cdot$先验均值 + $w_{data}\cdot m/n$

5 次全败: MLE=0；Beta(1,1)⇒Beta(1,6)⇒预测 1/7（贝叶斯避免极端）

⑨ 离散先验表格法（Q3）

π	先验	似然 $\pi^3(1-\pi)$	乘积	后验
0.2	0.2	0.0064	0.00128	0.0202
0.5	0.5	0.0625	0.03125	**0.4941**
0.8	0.3	0.1024	0.03072	0.4857

证据=Σ乘积=0.06325；MAP=0.5；后验预测=Σπ·后验=**0.6396**（≠MAP 代入 0.5）

⑩ 高斯-高斯共轭

精度=1/方差：$\lambda_0=1/\tau_0^2$，$\lambda_D=n/\sigma^2$

$\mu_n=(\lambda_0\mu_0+\lambda_D\bar{x})/(\lambda_0+\lambda_D)$；$\tau_n^2=1/(\lambda_0+\lambda_D)$；预测 $x^*\sim N(\mu_n,\sigma^2+\tau_n^2)$

例: μ~N(10,4), n=2, $\bar{x}$=14, σ^2=8：$\lambda_0=\lambda_D=0.25$（等权）⇒ $\mu_n=$**12**, $\tau_n^2=$**2**；预测 N(12, 8+2=10)（预测方差=参数不确定+新噪声，更大）

例2: N(10,4), n=4, $\bar{x}$=12, σ^2=4：$\lambda_D=1$ ⇒ $\mu_n=0.2\cdot10+0.8\cdot12=11.6$, $\tau_n^2=0.8$

$\tau_0^2\to\infty$ 或 $n\to\infty$ ⇒ $\mu_n\to\bar{x}$=MLE；谁精度高谁权重大

⑪ MAP / 正则化 / 软阈值

MAP = 最小化(−log似然 −log先验)。高斯先验 $N(0,\tau^2)$ ⇒ L2：$\|y-Xw\|^2+\lambda\|w\|^2$, $\lambda=\sigma^2/\tau^2$（岭回归）；拉普拉斯先验 ⇒ L1（稀疏，可压到 0）

先验中心 w_0: 惩罚 $\|w-w_0\|^2$ ⇒ **$(X^TX+\lambda I)\hat{w}=X^Ty+\lambda w_0$**；$w_0=0$⇒标准岭；

$\tau^2\to\infty$⇒λ→0⇒OLS

岭稳定机制：X^TX 近奇异（特征共线）时 +λI 抬高小特征值

Q7 拉普拉斯 MAP:

$L(w)=n/(2\sigma^2)\cdot(w-\bar{x})^2+\lambda|w|$（用 $\Sigma(x_i-w)^2=\Sigma(x_i-\bar{x})^2+n(w-\bar{x})^2$）。w>0: $w=\bar{x}-\lambda\sigma^2/n$（当 $\bar{x}>\lambda\sigma^2/n$）；w<0 对称；$|\bar{x}|\le\lambda\sigma^2/n \Rightarrow \hat{w}=0$。合并：**$\hat{w}=\text{sign}(\bar{x})\max(|\bar{x}|-\lambda\sigma^2/n, 0)$**

⑫ 噪声→损失

高斯噪声 ⇒ $-\log\propto\Sigma r_i^2$（平方，r=10⇒100）；拉普拉斯 ⇒ $\Sigma|r_i|$（绝对值，稳健）。

⑬ 常用数值速算

√2=1.414	√3=1.732	√5=2.236	√(2π)=2.507	
1/√(2π)=0.3989 = 1/2.507				
$e^{-0.5}$=0.607	e^{-1}=0.368	$e^{-1.5}$=0.223	e^{-2}=0.135	e^{-4}=0.0183
$e^{-0.125}$=0.882	$e^{-2.25}$=0.105	e^{-8}=0.0003	⅓≈0.333	⅔≈0.667

一维高斯代入模板：先算 $z=(x-\mu)/\sigma$，则 $N(x|\mu,\sigma^2)=(1/\sigma)\cdot0.3989\cdot e^{-z^2/2}$。如 $\sigma^2=2 \Rightarrow 0.2821\cdot e^{-z^2/2}$；$\sigma^2=1 \Rightarrow 0.3989\cdot e^{-z^2/2}$。

⑭ 英文题面关键词 → 模板

posterior / prior / update belief	→ ② 表格法 / ⑧ Beta
larger density, not Euclidean	→ ④ 马氏距离
derive MLE / closed form	→ ⑥ 四步
fit regression / predict at x*	→ ⑦ 列表法
posterior predictive / next trial	→ ⑧⑨ 均值加权
MAP / prior∝exp(−λ|w|) / ridge	→ ⑪ 软阈值/岭
update centroids / assignment	→ ⑰ K-means
responsibilities / EM iteration	→ ⑱ E+M 三式
as $\sigma^2\to0$ / limit / hard assignment	→ ⑱ 极限推导
bandwidth / kernel / density	→ ⑲ KDE
mode / mean shift	→ ⑳ 均值漂移
partition / Ncut / Laplacian	→ ㉑ 谱聚类

⑮ 简答题模板（问法→答题要点）

方差为何 n−1?	均值由同数据估出，Σ残差=0 损失 1 自由度；MLE÷n 偏小，÷(n−1) 无偏
MAP≠后验均值?	众数 vs 全分布平均；后验不对称时分叉（B(2,5): 0.286 vs 0.2）
后验预测≠代 MAP?	按后验对所有参数加权平均，保留不确定性（5 败: MLE 预测 0，贝叶斯 1/7）
敏感性 vs 后验?	P(+|D) 患病中阳性 vs P(D|+) 阳性中患病；基础率低⇒后验≪敏感性
先验何时帮/害?	帮：真实先验、稳定共线/高维；害：强+错+未检验
为何 EM 不直接 MLE?	log(Σ) 耦合无闭式；Jensen 下界每步似然不减；仅局部最优
K-means 收敛?	两步各使 J 不增+分配有限⇒不动点；局部最优、初始化敏感
K-means 失败场景?	球形假设被违反：长条/密度不均/非凸/离群拉均值
GMM vs K-means?	软概率 vs 硬分配；椭球各Σ_k vs 球；GMM 可过拟合（$\sigma^2\to0$，防护 $N_k\ge5$）
岭回归为何稳?	共线⇒X^TX 病态系数乱跳；+λI 抬小特征值；$\lambda=\sigma^2/\tau^2$
高斯 vs 拉普拉斯噪声?	Σr_i^2 vs $\Sigma|r_i|$；平方放大大误差（r=10: 100 vs 10）

⑯ 矩阵求导 + 正规方程推导

f(w)	a^Tw	w^Tw	w^TAw(对称)
$\nabla_w f$	a	2w	2Aw

$J=\|y-Xw\|^2=y^Ty-2w^TX^Ty+w^TX^TXw$；$\nabla=-2X^Ty+2X^TXw=0 \Rightarrow X^TX\hat{w}=X^Ty$

几何：残差 r=y−Xŵ 满足 **$X^Tr=0$**（r⊥X 各列，无方向可再降残差）；$\nabla J=-2X^Tr$（X^T 把 $\mathbb{R}^n$ 映回 $\mathbb{R}^d$）

避免显式 $(X^TX)^{-1}$（病态）→ QR/SVD；两列几乎相同 ⇒ X^TX 病态、权重不稳

2×2 验算：$\lambda_1+\lambda_2$=trace；$\lambda_1\lambda_2$=det（算完特征值必查）

点积/投影：$a^Tb=\|a\|\|b\|\cos\theta$；投影长度 $=a^Tb/\|b\|$

常用导数：$d/d\mu(x-\mu)^2=-2(x-\mu)$；d/dv log v=1/v；d/dw |w|=sign(w)

⑰ K-means

$J=\Sigma_i\Sigma_k r_{ik}\|x_i-\mu_k\|^2$（簇内平方和；$r_{ik}\in\{0,1\}$，$\Sigma_k r_{ik}=1$）

循环：**①初始化 ②分配=最近中心 ③中心=成员均值 $\mu_k=\Sigma r_{ik}x_i/\Sigma r_{ik}$ ④重复至不变。**每步 J 不降+分配有限⇒收敛（仅局部最优，初始化敏感→多次取 J 最小 / K-means++（按 $D(x)^2$ 概率选远点））

例: 点 {1,2,7,8}，μ=1,5：|x−μ₁|=(0,1,6,7)，|x−μ₂|=(4,3,2,3) ⇒ {1,2}|{7,8}；μ→1.5, 7.5；J：14→1；再分配不变⇒停

假设：球形/欧氏=相似/均值有意义。失败：长条、密度不均、非凸（环/月牙）、离群点拉偏均值。

⑱ GMM + EM（大题）

$p(x)=\Sigma_k\pi_kN(x|\mu_k,\Sigma_k)$；生成：$P(z=k)=\pi_k$ → $x\sim N(\mu_k,\Sigma_k)$

E: $\gamma_{ik}=\pi_kN(x_i|\mu_k,\sigma_k^2)/\Sigma_j\pi_jN(x_i|\mu_j,\sigma_j^2)$（每点 $\Sigma_k\gamma=1$；=归一化 先验×似然）

M: $N_k=\Sigma_i\gamma_{ik}$；$\pi_k^{new}=N_k/n$；$\mu_k^{new}=\Sigma\gamma_{ik}x_i/N_k$；$\sigma_k^{2new}=\Sigma\gamma_{ik}(x_i-\mu_k^{new})^2/N_k$（软计数→位置→散布；$\sigma^2$ 用**新** μ！）

Q4 完整例: x={0,2,4}；π=(0.6,0.4)，μ=(0,4)，$\sigma^2=2$。
一维 N 值：N(0|0,2)=.2821，N(2|0,2)=N(2|4,2)=.1038（对称⇒γ 只由 π 定=(0.6,0.4)），N(4|0,2)=.0052
γ 表：(0.9879,0.0121) / (0.6,0.4) / (0.0267,0.9733)
N_1=1.6147, N_2=1.3853（和=3✓）⇒ π=(**0.5382**, 0.4618)；μ=(**0.8094**, **3.3877**)；σ^2=(**1.10**, **0.92**)
讲义例 x={1,3,5}, π=½½, μ=(1,5), σ^2=1：γ=(0.9997,.0003)/(.5,.5)/(.0003,.9997)；N=1.5/1.5；μ=(1.668, 4.332)；σ^2=0.891（中点各半贡献）

t4 例（直接给 p(x|z)）：s=π·p=(0.18,0.15,0.12)，Σ=0.45 ⇒ γ=(0.40,0.33,0.27)——大 π_k 不一定大 γ（似然也重要）。

M 步目标（Q 函数）：$Q(\theta)=\Sigma_i\Sigma_k\gamma_{ik}[\log\pi_k+\log N(x_i|\mu_k,\Sigma_k)]$（加权 MLE）；GMM 对数似然 $\ell(\theta)=\Sigma_i\log(\Sigma_k\pi_kN(x_i|\mu_k,\Sigma_k))$。

为何 EM：$\ell=\Sigma\log(\Sigma\pi N)$ 的 log(和) 使方程耦合无闭式。Jensen 构造下界 $L(q,\theta)\le\ell$；E 步 q=p(z|x) 使下界贴紧（gap=$KL(q\|p)\ge0$），M 步最大化下界⇒似然不减，收敛局部最优。

GMM→K-means（Q8）：$\pi_k=1/K$, $\Sigma=\sigma^2I$ ⇒ $\gamma_{ik}=\exp(-\|x-\mu_k\|^2/2\sigma^2)/\Sigma_j\exp(-\|x-\mu_j\|^2/2\sigma^2)$；比值 $\gamma_a/\gamma_b=\exp[(\|x-\mu_b\|^2-\|x-\mu_a\|^2)/2\sigma^2]$；$\sigma^2\to0$ 且 k* 唯一最近 ⇒ $\gamma_{ik^*}\to1$ 其余→0（硬分配）；M 步变 μ_k=成员均值 = K-means。

补充: 协方差结构 Spherical(σ^2I，等价 K-means 假设)/Diagonal/Shared/Full；过拟合：分量坍缩 $\sigma^2\to0$ 似然∞ → 防护 $N_k\ge5$、方差下限、验证集；BIC=−2logL+d·logN（越小越好，选 K）；分量数≠真实类数。

⑲ KDE

$\hat{p}(x)=1/(nh)\cdot\Sigma_iK((x-x_i)/h)$（d 维：$1/(nh^d)$）

核：高斯 $1/\sqrt{(2\pi)}\cdot e^{-u^2/2}$；Box: |u|≤1 取 ½；三角 max(0,1−|u|)。1/h 保面积=1；密度≠概率

局部推导：$2r\cdot p(x)\approx N_r(x)/n$ ⇒ $\hat{p}=N_r(x)/(2nr)$；直方图=计数/(nh)，缺陷：不连续+对 bin 起点敏感

h 小：尖峰/方差大（训练点间隙可为 0）；h 大：平滑/偏差大；**h 用验证集选**（训练集 h→0 密度→∞ 过拟合）

多维先特征归一化；维度灾难 h^d

例 {0,2,3} 三角核求 x=2：h=1 ⇒ 只有自身 K(0)=1 ⇒ 1/3；h=2 ⇒ (K(1),K(0),K(.5))=(0,1,0.5) ⇒ 1.5/6=**1/4**。验证 x=1：h=1⇒0；h=2⇒(0.5+0.5+0)/6=1/6 ⇒ 选 h=2

⑳ 均值漂移

$x^{new}=x+m(x)$，$m=\Sigma w_ix_i/\Sigma w_i-x$，$w_i=\exp(-\|x-x_i\|^2/2h^2)$

簇心=密度峰（KDE 梯度上升），无需 K；h 小⇒多簇，h 大⇒合并；峰=吸引盆，同盆同簇

例 {0,2,4}，x=1，h=2：w=(.8825,.8825,.3247) ⇒ x′=3.064/2.090≈**1.47**；课堂例 {0,1,2,3} h=1 x_0=2→1.355→0.778

vs K-means：软权重/任意形状/无需 K；但 $O(n^2d)$ 贵

㉑ 谱聚类

$w_{ij}=e^{-\|xi-xj\|^2/\sigma^2}$；D=diag(行和)；**L=D−W**（每行和 0）；$f^TLf=\frac{1}{2}\Sigma w_{ij}(f_i-f_j)^2$（平滑度）

Ncut(A,B)=cut(A,B)/vol(A)+cut(A,B)/vol(B)（vol=簇内度之和）；**小者优**（惩罚孤立小簇）；NP难→松弛 Lf=λDf 取前 k 小非零特征向量→新空间 K-means。加速：kNN 图代替全连接，$O(n^3)$→稀疏求解。

t5 例 W=[[0,3,0,0],[3,0,1,0],[0,1,0,3],[0,0,3,0]]：D=diag(3,4,4,3)
P_1={1,2}|{3,4}：cut=1（2–3 边），vol 7/7 ⇒ Ncut=2/7≈**0.286**
P_2={1}|{2,3,4}：cut=3，vol 3/11 ⇒ Ncut=1+3/11≈1.273 ⇒ P_1 优；f=[1,1,0,0] ⇒ f^TLf=2×跨割权/2=1

四聚类对比：K-means 球形 $O(nkd)$ | GMM 概率软分配 | mean-shift 密度峰 $O(n^2d)$ | 谱聚类非凸 $O(n^3)$ 最贵。

㉒ 英文术语速查（读题用）

prior 先验	posterior 后验	likelihood 似然	evidence 证据
conjugate 共轭	posterior predictive 后验预测	MAP 最大后验	MLE 极大似然
mean 均值	variance 方差	covariance 协方差	correlation 相关
precision =1/var 精度	bias 偏差	unbiased 无偏	i.i.d. 独立同分布
inverse 逆	determinant(det) 行列式	trace 迹	eigenvalue/vector 特征值/向量
residual 残差	normal equations 正规方程	least squares 最小二乘	projection 投影
ridge regression 岭回归	penalty 惩罚项	regularization 正则化	shrinkage 收缩
overfitting 过拟合	generalization 泛化	validation 验证(集)	training 训练
assignment 分配	centroid 质心	within-cluster 簇内	convergence 收敛
mixture 混合	component 分量	responsibility 责任 γ	hard/soft 硬/软分配
mixing weight 混合权重	covariance 结构 spherical/diag/shared/full	lower bound 下界	KL divergence KL散度
bandwidth 带宽	kernel 核	density estimation 密度估计	mode 众数/峰
similarity 相似度	graph cut 割	volume 体积vol	Laplacian 拉普拉斯
sensitivity 敏感性	specificity 特异度	recall 召回	precision(分类) 精确率