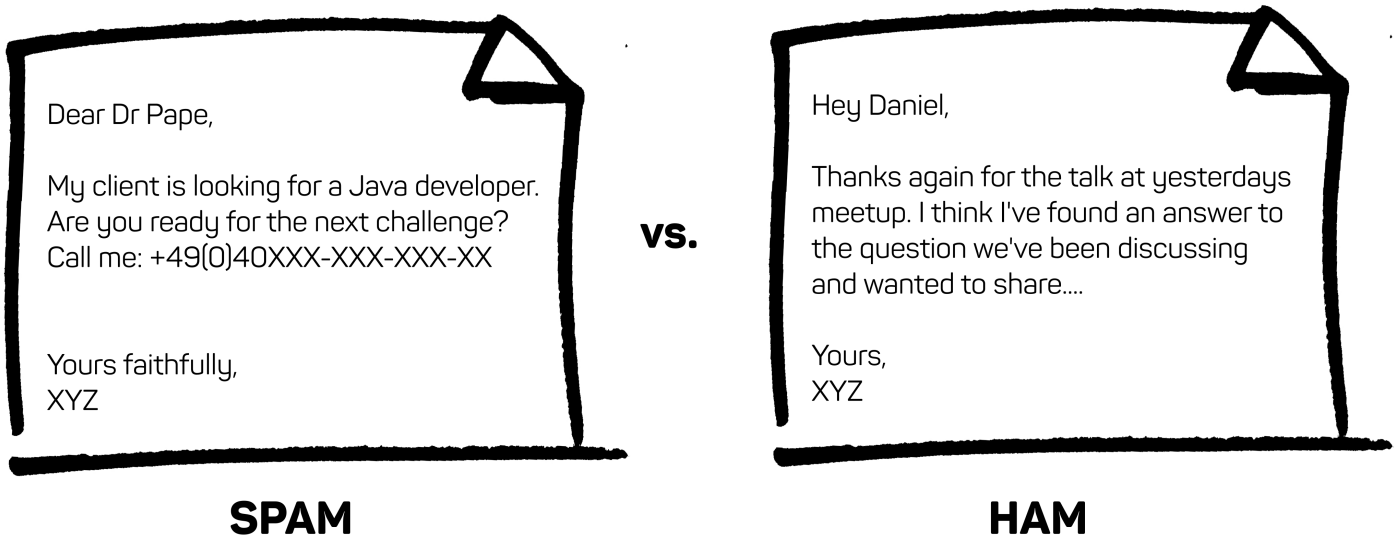
马凯德

香港市大学(东川)

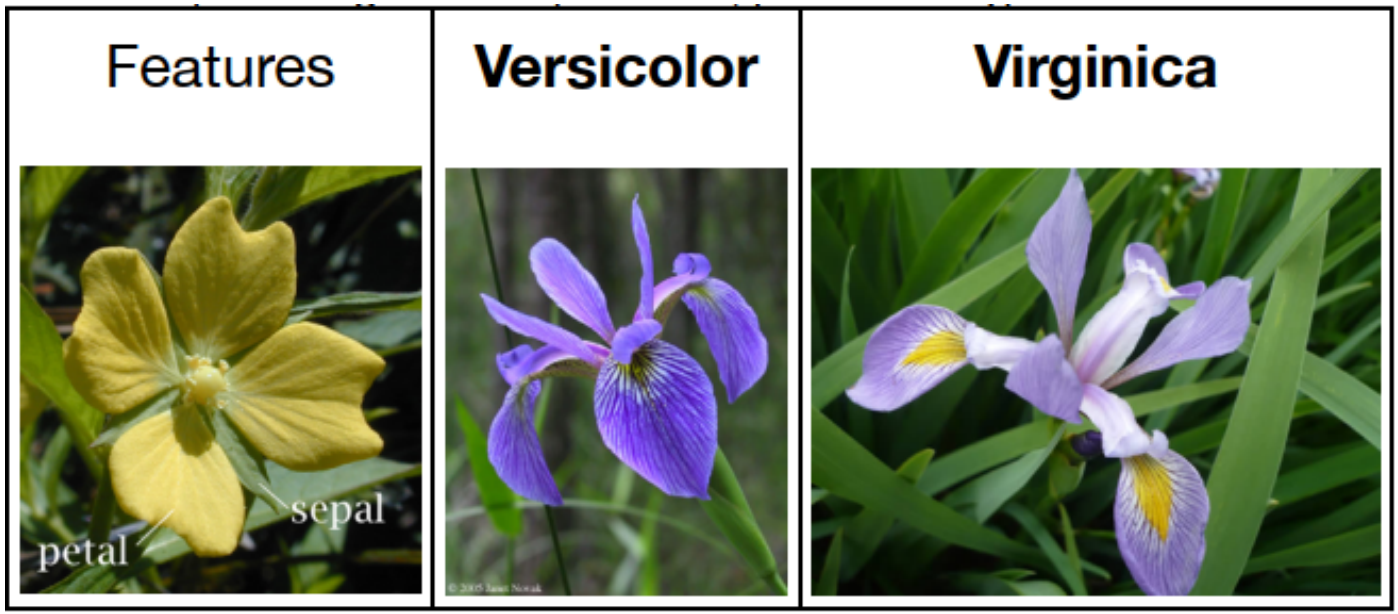


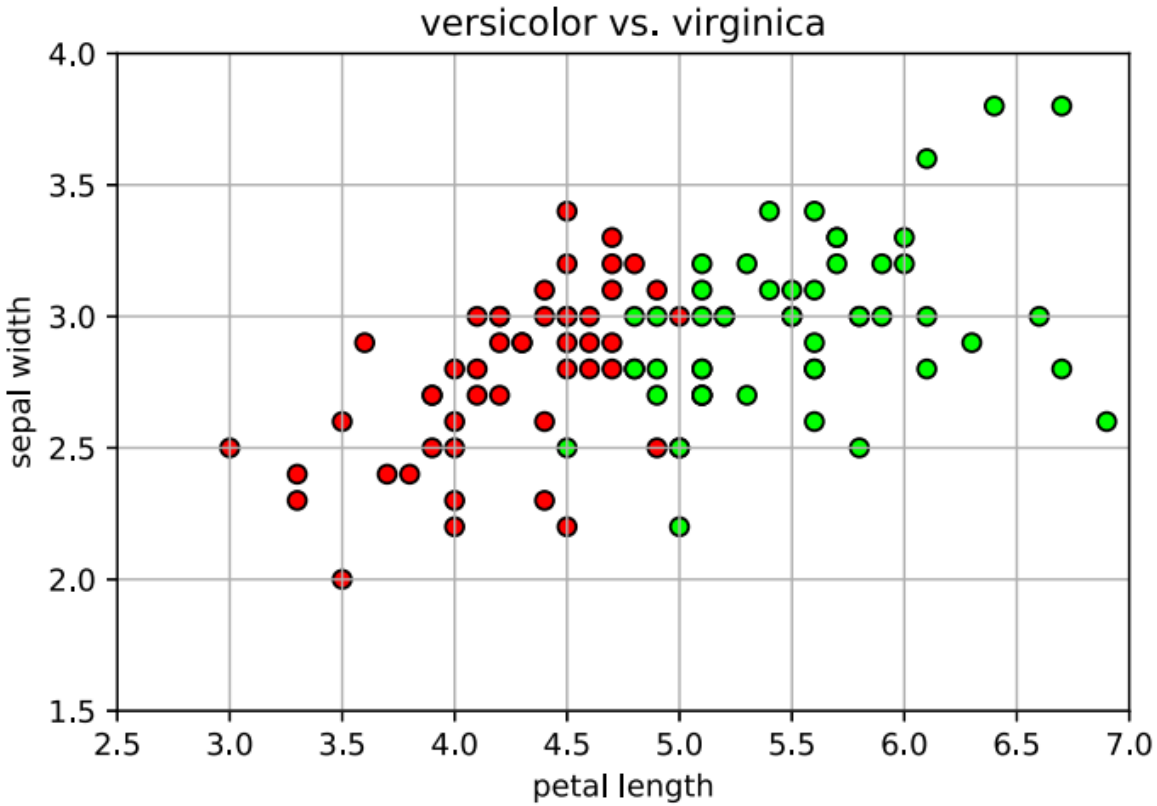
Benjamin M. Marlin提供的幻灯片模板

- 使用电子邮件预测是垃圾邮件还是不是垃圾邮件



- 鉴于花朵的花瓣长度和花瓣宽度，预测花朵的虹膜。
  物种种类




versicolor vs. virginica
sepal width
petal length
4.0
3.5
3.0
2.5
2.0
1.5
2.5
3.0
3.5
4.0
4.5
5.0
5.5
6.0
6.5
7.0

给给定特性矢量 x RN, 描述属于该天体的天体

设置 Y 的 C 类之一,预测对象的类别

属于

- 在先前的虹膜分类例子中
  - $\mathbf{x} = \begin{matrix} \text{花瓣长度} \\ \text{sepal 宽度} \end{matrix} = \begin{matrix} x_1 \\ x_2 \end{matrix}$ #R2 N=2
  - Y = {"versicolor","virginica"},在那里~~~

给定示例对 D = {(x(i), y(i)), i = 1,.., M} 的数据集
x(i) {{RN 是特性矢量, y(i) {Y= {1,.,., C} 是a

类标签,学习函数 f: RN 7Y,精确预测

对于任何特性矢量 x 而言,类标签 Y Y 类标签 Y

$$\mathbb{I}[A] = \begin{cases} 1, & \text{如果事件A发生} \\ 0, & \text{以其他方式} \end{cases}$$

给定示例对 D = {(x(i), y(i)), i = 1,.., M} 和 {(x(i), y(i)) 的数据集
a 函数 f: RN 7Y, F对 D 的分类错误率为

E(f,D)=1 $-\sum_{i=1}\mathbb{I}[y^{(i)} \neq f(\mathbf{x}^{(i)})]$

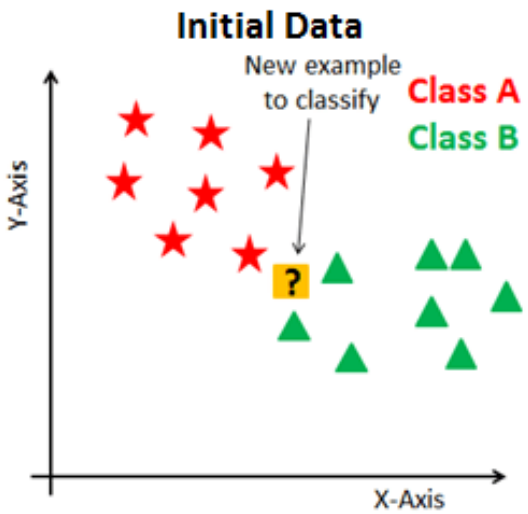
给定示例对 D = {(x(i), y(i)), i = 1,.., M} 和 {(x(i), y(i)) 的数据集
a 函数 f: RN 7Y, D 的 f 分类精确率为

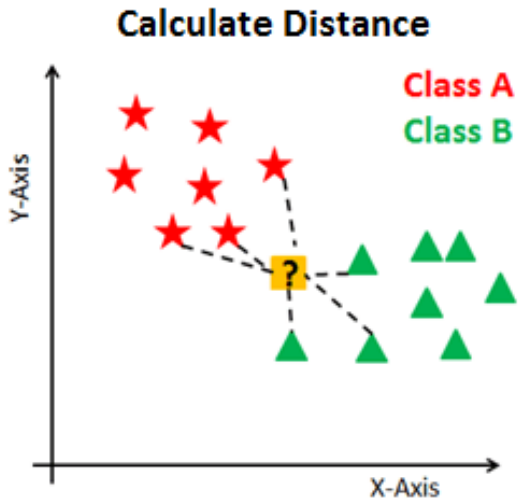
A(f、D) = 1 $-\sum_{i=1}\mathbb{I}[y^{(i)} = f(\mathbf{x}^{(i)})]$

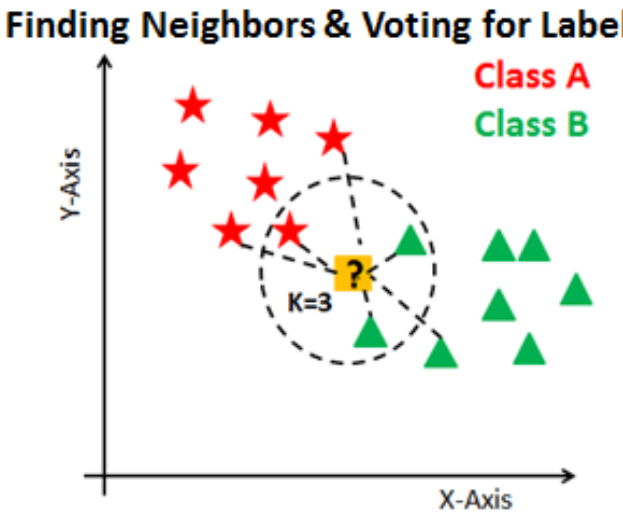
- KNN 分类器是最简单但最重要的
  机器学习中的分类

- 它储存培训成套D组，对每个新实例进行分类x
  对拥有指数的K近邻使用多数票
  $\mathcal{N}_K(\mathbf{x}) \subset \{1, \ldots, M\}$

- 使用 KNNN 需要选择距离函数
  d: RN × RN 7R和邻居K的数量


Initial Data
New example
to classify
Class A
Class B
Y-Axis
X-Axis
?


Calculate Distance
Class A
Class B
Y-Axis
X-Axis
?


Finding Neighbors & Voting for Labels
Class A
Class B
Y-Axis
X-Axis
?
K=3

x\%D 返回函数 f(x) 的最大运算符
函数的最大值 :

$$\text{最大}_{\mathbf{x}\%\mathcal{D}} f(\mathbf{x}) = \{f(\mathbf{x}) | \mathbf{x} \in \mathcal{D} \wedge \forall \mathbf{y} \in \mathcal{D}, f(\mathbf{y}) \leq f(\mathbf{x})\}$$

x\\%D 定义的函数 f(x) 的最大 最大运算符
f(x) 达到最大值的一组点数 :

$$\text{最大值}_{\mathbf{x}\%\mathcal{D}} f(\mathbf{x}) = \{\mathbf{x} | \mathbf{x} \in \mathcal{D} \wedge \forall \mathbf{y} \in \mathcal{D}, f(\mathbf{y}) \leq f(\mathbf{x})\}$$

fKNN(x) = 最大值 $\mathbb{I}[y^{(i)} = c]$

$\in\{ ,\cdots, \}$ iNK(x)

- 一般说来,KNN可以使用任何远程功能工作d（x， x_） 和身份
  d(x， x） = 0

- 一般说来,距离功能的结构越多,（对称、三角不平等）结构越多
  设计算法时加以利用

根据两个数据矢量xxxxRN,Minkowski与

p p(lp-norm) 参数是一个适当的测量尺度,定义如下:

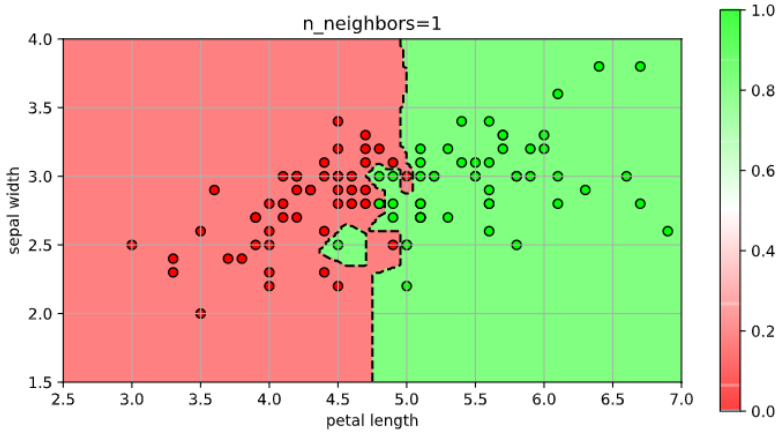
dp(x, x_) = x -x_x_p

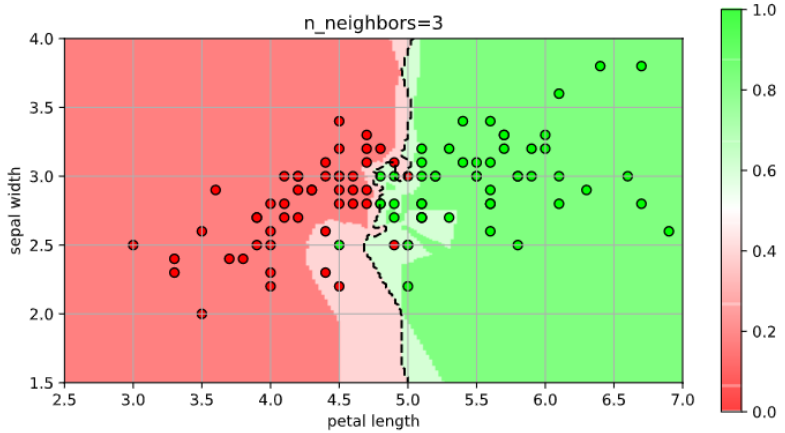
$$= \left(\sum_{j=1}^{N} \tilde{\tilde{\tilde{\

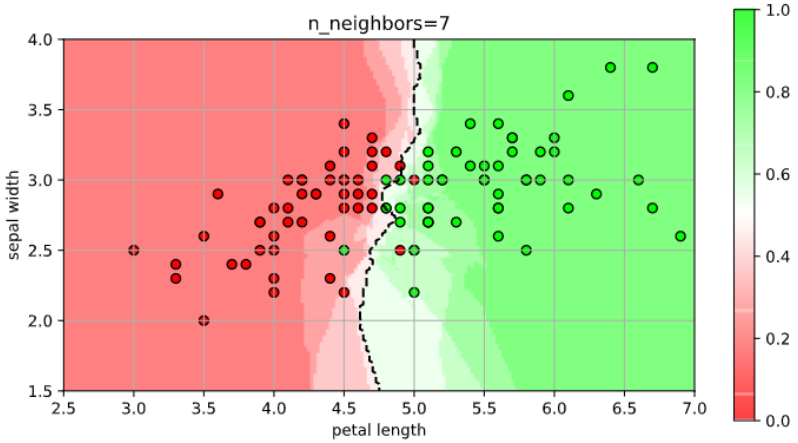
- 根据任何距离功能d,布鲁特人迫使KNN
  从目标点 x 到所有计算距离 di = d(x(i), x)
  训练点 x(i)

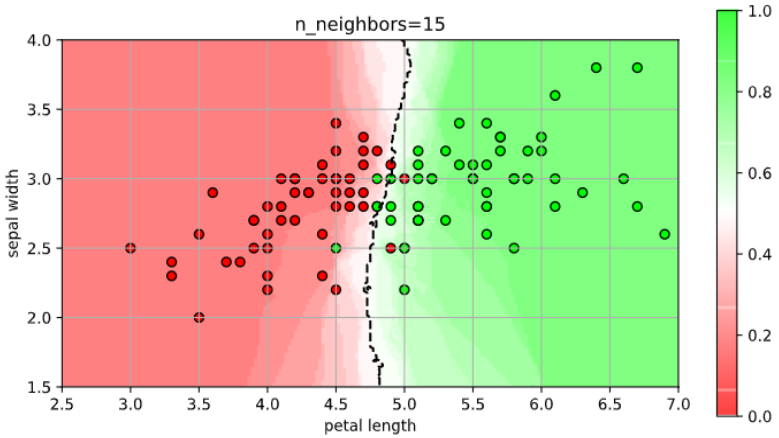
- 排序 {di, i = 1,......, M} 并选择数据大小写
  以 K 最小距离组成邻居索引集
  NK(x)

- K 邻居一旦被选中, 应用分类
  简单规则


n_neighbors=1
sepal width
petal length


n_neighbors=3
sepal width
petal length


n_neighbors=7
sepal width
petal length


n_neighbors=15
sepal width
petal length

- 而不是给予所有K邻居同等的权重
  多数票,可使用远距离加权多数:

$$fKNN(x) = \text{最大值}_{\in\{\ ,\ldots,\ \}} \frac{\sum_{i\in NK(x)} wi\,[y(i) = c]}{\sum_{i\in NK(x)} wi}\ ,$$

$$Wi = \exp(-di)$$

- 最近的邻居搜索 数据结构
  K-d 树树等 K-d 树可以在培训数据的基础上建造
  以较低的计算成本支持最近的邻居搜索

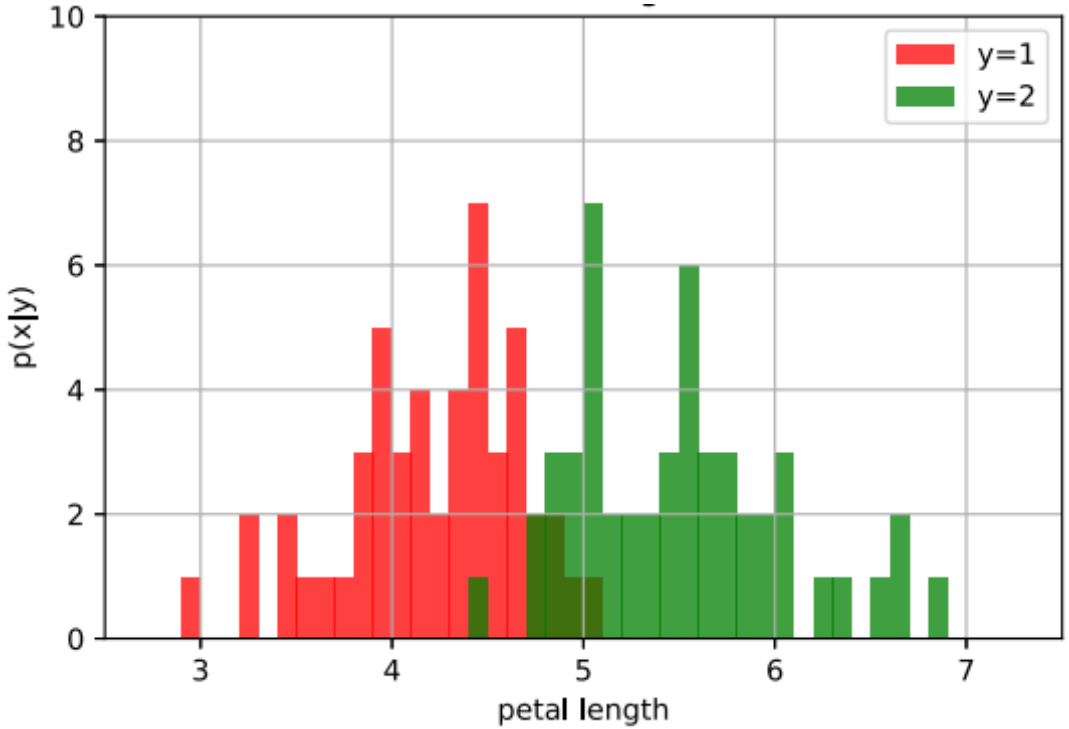
- 优点:
  - 不涉及任何培训期(即懒懒学习)和新数据
    无需再培训即可无缝添加模型
  - 随着数据进入无限度,对正确决定表面的连接
- 缺点:
  - 大型数据集工作不顺利。 由于 KNN 需要
    存储所有训练数据, 执行邻居搜索需要很多
    并花费很多时间
  - 工作效率不高,工作效率不高。
    计算每个维度的距离的 KNN。 此外,
    与所有事物相距甚远,
    (所谓“维度诅咒”)

- 代表一种类型的分类器来模拟数据
- 模拟如何利用概率分布生成数据
  (即, 基因模型)
- 界定基因变异模型:
  - 世界有各种种类的物体/类型
  - 观察员措施的特征/意见
    物体/类型
  - 每一类物体/模式都有特定的(而且可能
    特征的分布

- 可能的等级为Y类
  - 例如,在iris数据集中,Y = {“versicolor”、“virginica”},
    Y = {1, 2} = {1, 2}
- 在现实世界中,Y类的频率是由
  概率分布 p(y)
  - p(y) 称为先前的分配
- 示例:
  - p(y = 1) = 0.4和p(y = 2) = 0.6
  - 这意味着在有虹膜花的世界里, 40%的花是
    1类(versicolor)和60%为2类(virginica)
- 根据培训数据的估计:

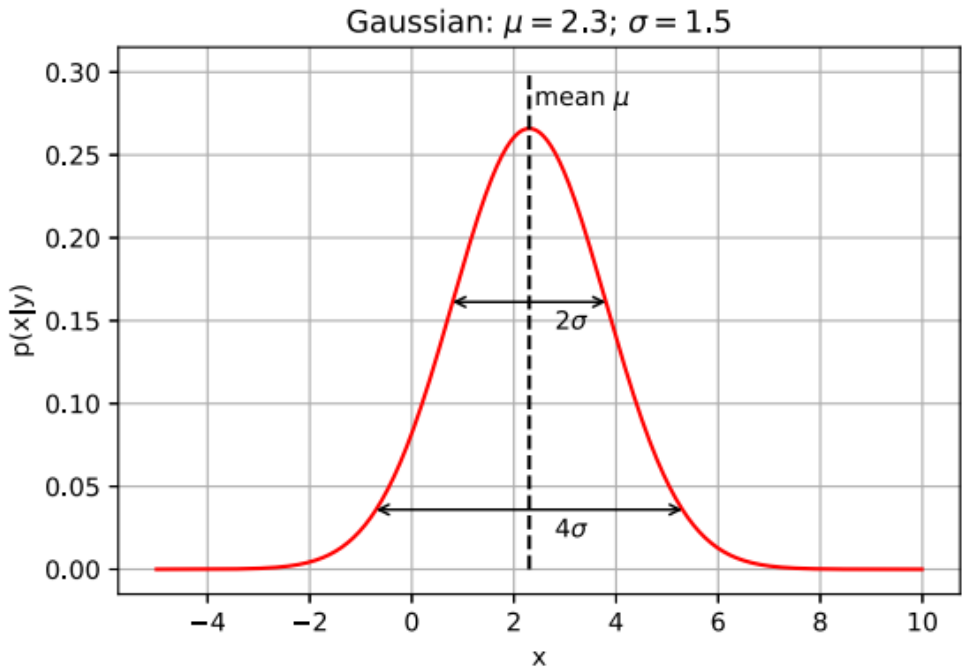
$$p(y = c) = \text{时} \sum_{i=1}^{\text{时}} I[y(\text{—})=c] \qquad c \in \{1,2\}$$

- 我们测量/观测一个特性矢量x
  - 特征值取决于类别
- 该观察根据 p(x) y 分布值绘制 。
  - p(xy) 被称为类有条件分配
  - 它表明观测某一特性矢量的概率
    x 如果对象为 Y 类, x 则该对象为 Y 类
- 根据培训数据的估计:
  - 在 iris 数据集中, 我们绘制“ 行星长度” 特征的直方图 每一班的每班



- 问题:看起来有点吵
- 解决方案:为该类设定一个参数概率模型
  条件 p(x y)

- 每一类的模型均以单列的Gaussian分配模式为模型。字符特性值
  - p(xy = c; μc, 2) = $\frac{1}{\sqrt{2\pi\sigma}}$ c e $\frac{1}{2\sigma_c^2}$ (xc)2 包括
  - 每个等级都有其本身的平均值和差异参数(微克c, 0.002))

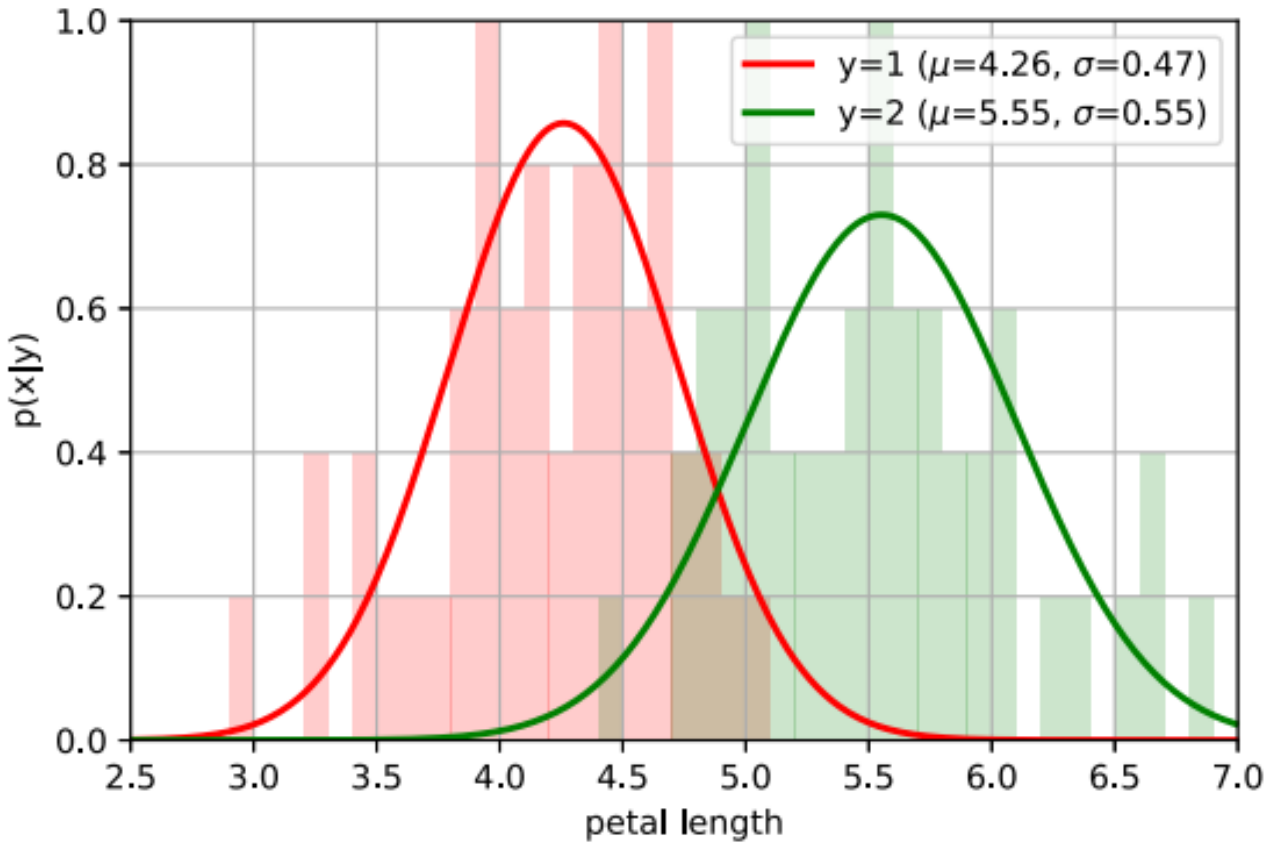


- 最大概率估计(MLE)
  - 设置参数(μc, 秒/ 秒)(c) 使可能性最大化
    C类样本(概率)
  - Let Dc = {x(i), y(ii)=1 是 c 类(即y(—) = c) 的数据 :
    MC

$$(,, \quad (c) = \text{最高值}_{\text{微 c,}\ -20002} \quad \text{麦克} \sum_{i=1} \log p(x(i)\ y(i)\ ; \mu c,\ 2)$$

  - 以上目标是观测到的数据的日志可能性,
    视为参数的函数(μc, ~ 12)

- 解决方案 :
  - $\mu c = \frac{\text{麦克 PM}\widehat{\ }_{i=1}}{\text{麦克 PP}_{x(—)}\ \text{PMc}}$
  - $= \frac{}{\text{麦克 PPc}\ _1 (x^{(i)} — \text{微克(c})2}$


y=1 (μ=4.26, σ=0.47)
y=2 (μ=5.55, σ=0.55)
p(x|y)
petal length
1.0
0.8
0.6
0.4
0.2
0.0
2.5
3.0
3.5
4.0
4.5
5.0
5.5
6.0
6.5
7.0

- Bayesian决定规则(BDR)作出了最佳决定
  涉及概率(不确定性)的问题
  - 最小化预测错误的概率
- Bayes 最佳分类法
  - 如果观察x,请选择 c 类与最大
    事后概率 p(y = cx):

$$fB(x) = \text{最大比例} p(y = cx)$$
$$\in \{ ,\ldots, \} \quad (y = cx)$$

- 示例:
  - 如果 p(y = 1 x) > p(y = 2x), 那么选择第 1类
  - 如果 p(y = 1x) < p(y = 2x), 那么选择第 2类
- 问题:我们没有p(yx)
  - 我们只有p(y)和p(x)j(y)

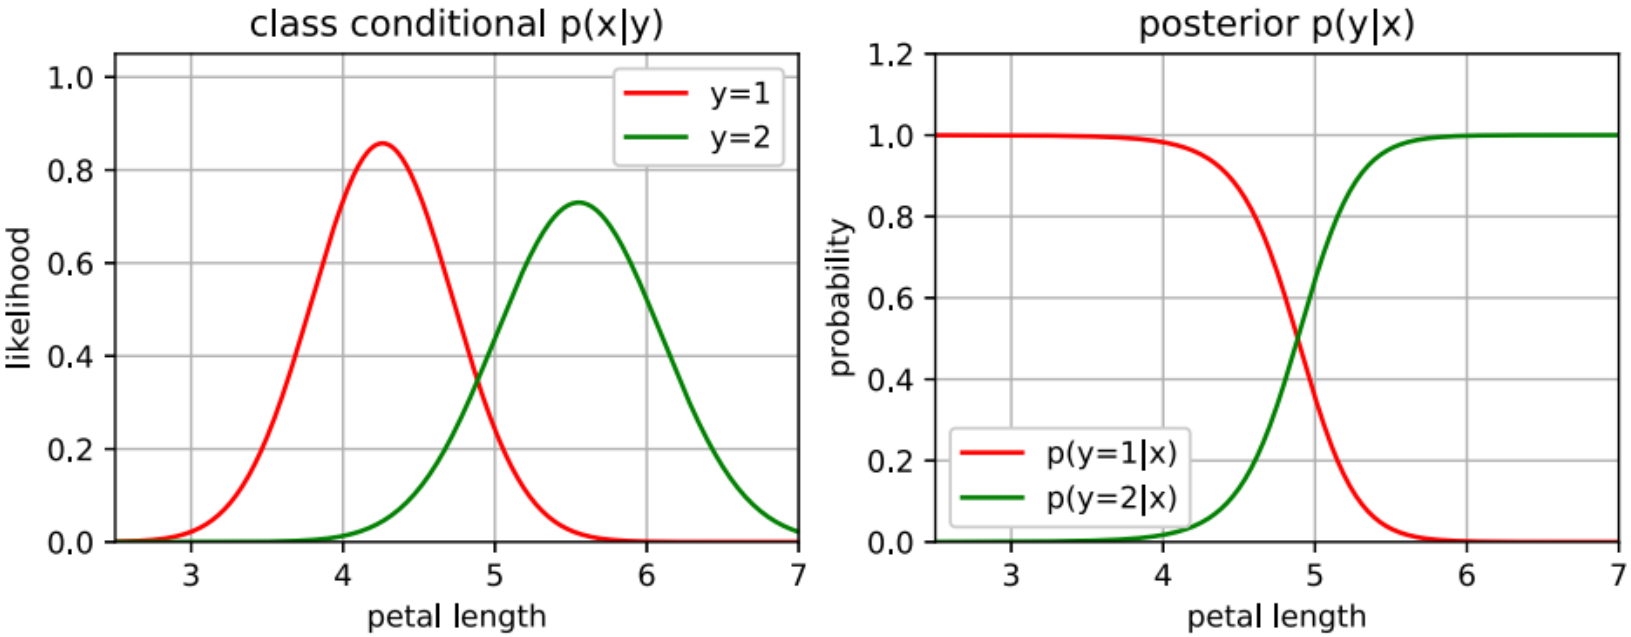
- 事后概率可以用拜斯规则计算:

$$p(y|\mathbf{x}) = \frac{p(\mathbf{x}|y)p(y)}{p(\mathbf{x})}$$

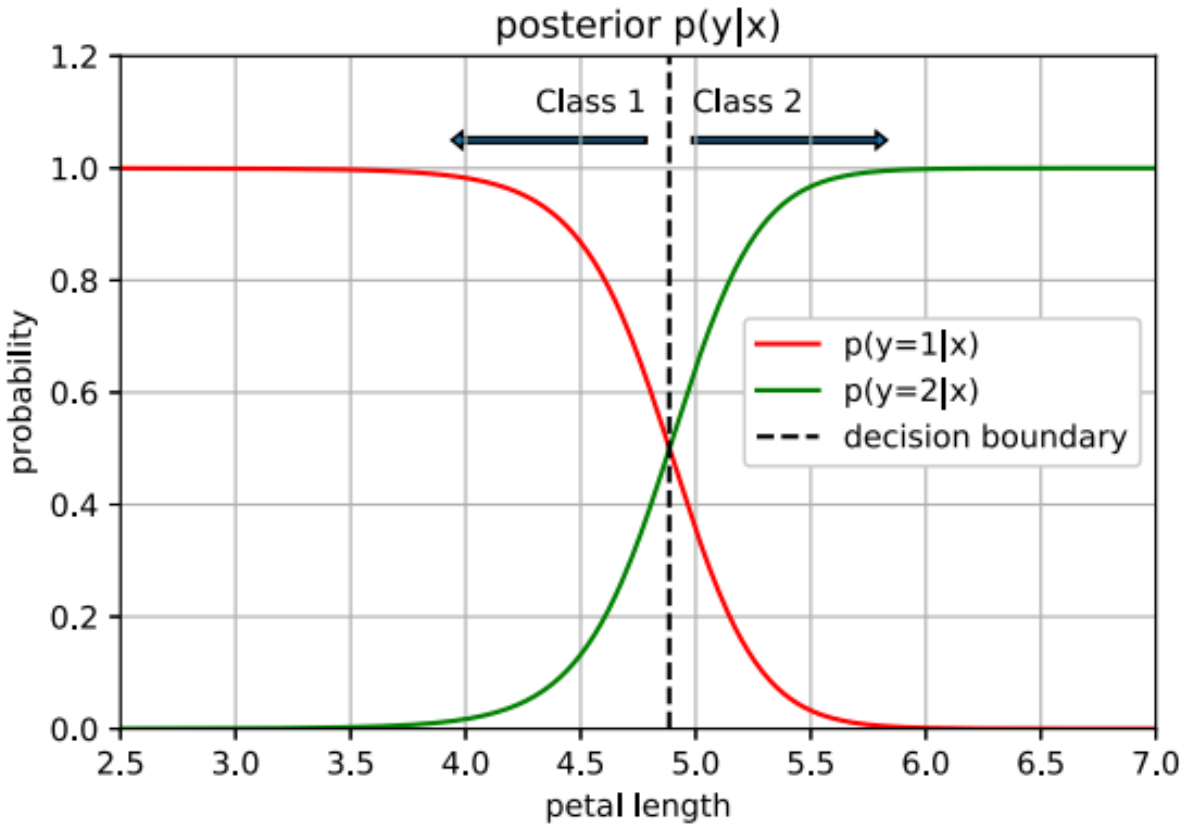
  - 分母是 x 的概率 :
    - p(x) = P yY p(x, y) = P yY p(xy) p(y)
  - 分母使 p(yx) 和为 1

- Bayes的规则:

$$p(y|\mathbf{x}) = \frac{p(\mathbf{x}\ y)p(y)}{\text{p(xy = 1) p(y) = 1) + p(xy = 2) p(y) = 2)}}$$


class conditional p(x|y)
likelihood
petal length
y=1
y=2
posterior p(y|x)
probability
petal length
p(y=1|x)
p(y=2|x)

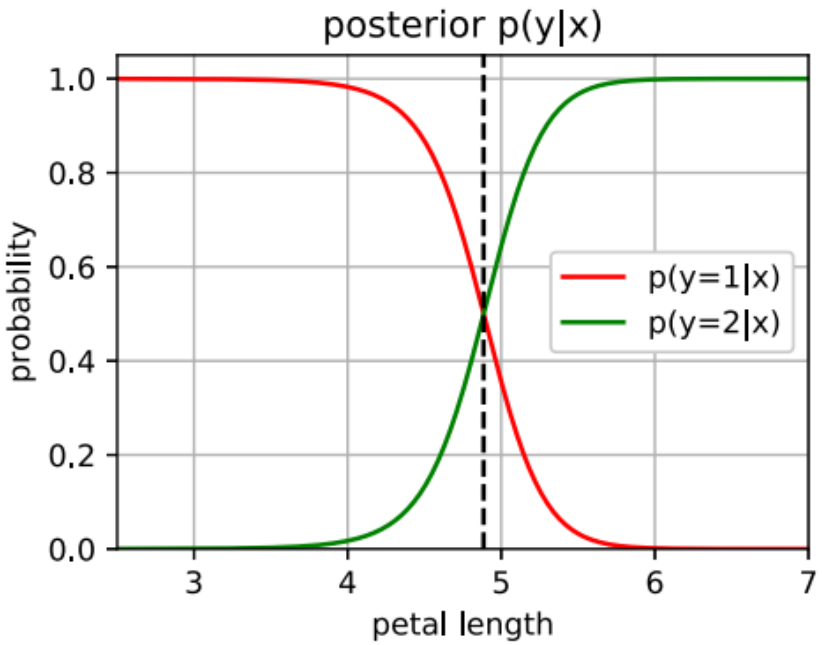
- 决定边界是两个后期可能性所在相等
  - p(y = 1x) = p(y = 2x)

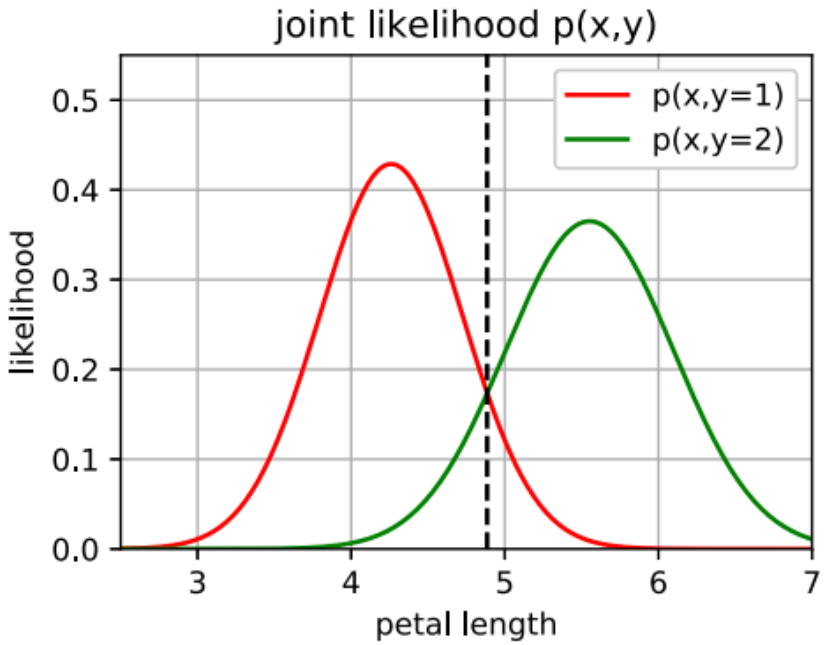


- Bayes的规则:

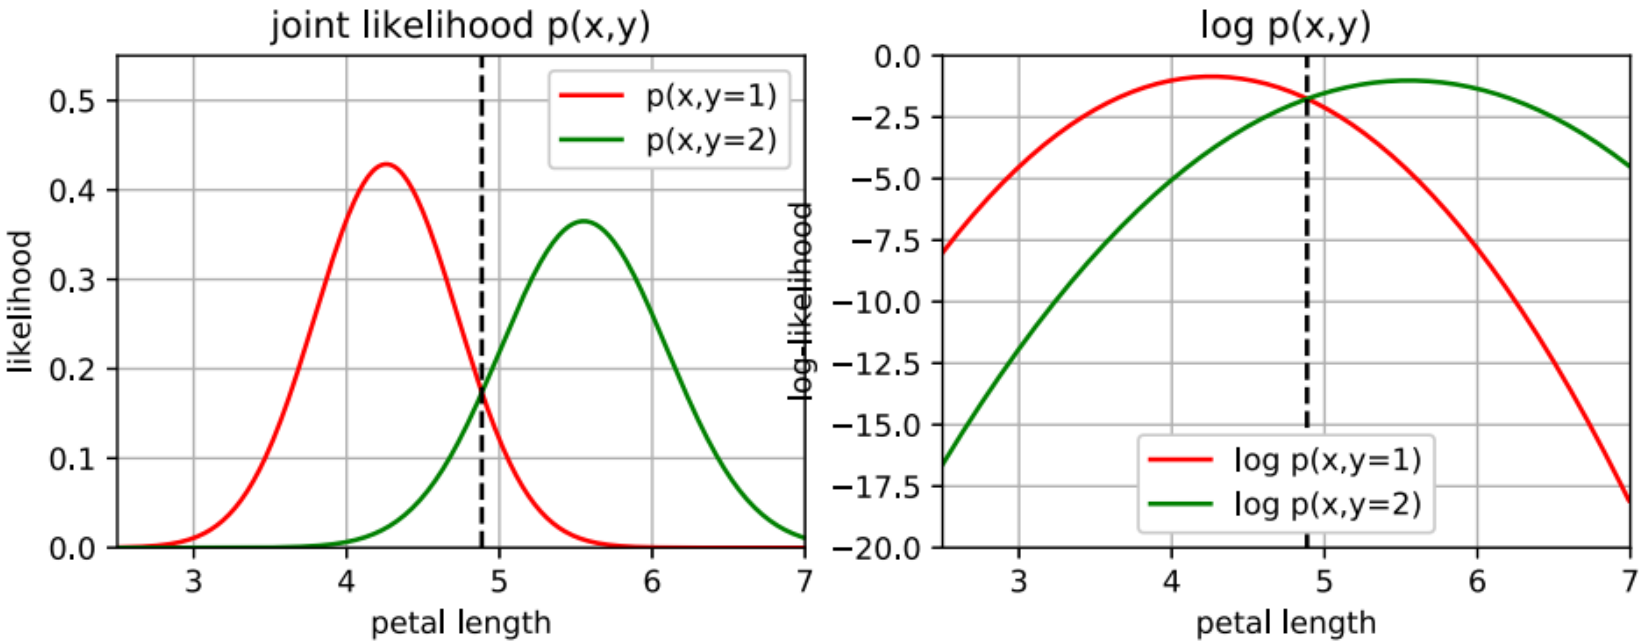
$$p(y|\mathbf{x}) = \frac{p(\mathbf{x}|y)p(y)}{p(\mathbf{x})}$$

- 请注意,每类y的分母相同。
  - 因此,我们只能比较分子p(xy)p(y)
  - 这也要求共同进行观察的可能性和类别
    - (x, y) = p(x) y) p(y)
- 示例:
  - 使用共同可能性的BDR:
    - 如果p(xy=1)p(y=1) >p(xy=2)p(y=2)p(y=2),那么选择第1类
    - 否则,请选择第2类


posterior p(y|x)
probability
petal length
p(y=1|x)
p(y=2|x)
1.0
0.8
0.6
0.4
0.2
0.0
3
4
5
6
7


joint likelihood p(x,y)
likelihood
petal length
p(x,y=1)
p(x,y=2)
0.5
0.4
0.3
0.2
0.1
0.0
3
4
5
6
7

- 也可以适用严格增加的函数(如日志)比较
  - 使用日志可能性 ：
    - log p(xy = 1) + log p(y) = 1) > log p(xy = 2) + log p(y) = 2
  - 当可能性很小时,这个数值会更稳定



- 培训:
  - $p(\ |y = c)$:
    1. 选择分布的形式(例如, Gaussian)
    2. 估计其与MLE的参数
- 分类:
  - 每个级别c
    - 等值,使用 p(xy = c)p(y = c)或 log p(xy = c) + log p(y) = c)