

本次机器学习课程讲解凸优化与 SVM 基础。明确 GD、SGD 及 Mini-batch GD 的区别与适用场景；介绍 SVM 最大间隔原则、硬/软间隔及 Hinge Loss，对比 Logistic 回归的概率方法；说明多分类采用 One-vs-One 或 One-vs-Rest 策略。通知 9 月 20 日因中秋国庆假期安排补课，课后由黄振明博士带领 Tutorial。

凸优化基础概念与判定条件

- **凸集与凸组合定义**
  - 线段（原文称 nice segment）连接两点 x 和 y 的所有点构成凸组合，要求系数 α 严格限制在[0,1]区间内
  - 凸集定义为其包含任意两点间整条线段的集合，证明非凸只需找到一个反例点对使线段部分落在集合外
  - 超平面与半空间均为凸集，可通过代数验证任意两点的凸组合仍满足不等式约束
- **凸函数性质与判定方法**
  - 凸函数要求定义域为凸集且满足 Jensen 不等式，几何上表现为弦始终位于曲线上方
  - 一阶条件指出可微函数为凸当且仅当其一级 Taylor 展开是全局下估计，即 $f(y) \geqslant f(x) + \nabla f(x)^{T}(y-x)$
  - 二阶条件要求 Hessian 矩阵半正定，这是标量非负性在矩阵情形的推广，并非要求所有元素为正
  - 仿射函数同时为凸且凹，是唯一兼具两种性质的函数类型；指数函数、范数、谱范数均为凸函数
- **Logistic 损失凸性证明**
  - Logistic 损失函数 $f(x)=\log(1+e^{-x})$通过求二阶导数验证其恒大于零，从而确认为凸函数
  - 该凸性保证了 Logistic 回归虽无闭式解，但可通过数值优化求得全局最优

梯度下降算法变体与收敛特性

- **批量梯度下降（GD）机制与局限**
  - GD 每次迭代需计算全部样本梯度之和，计算复杂度随样本量 M 线性增长，难以扩展至百万级以上数据集
  - 停止准则包括参数变化量小于 ε=1e-6、梯度范数小于阈值或达到预设最大迭代次数（如 2000 次）

- 学习率 α 需足够小以保证一阶近似有效，过大导致发散，过小导致收敛过慢；无通用最优值，依赖经验调试
- 初始点选择显著影响最终收敛位置，建议多次随机初始化取最优解

· **随机与小批量梯度下降对比**
- SGD 每次仅用一个样本估计梯度，计算代价为常数级，期望意义下为真实梯度的无偏估计
- SGD 轨迹噪声大，目标函数值非单调下降，但振荡特性有助于逃离局部极小；丧失向量化运算优势
- Mini-batch GD 折中二者，使用小批样本平均梯度，兼顾计算效率与稳定性，为深度学习默认优化方法
- 深度学习常用学习率调度策略包括 Warm-up、衰减及末期 Stamping 阶段

支持向量机原始形式与间隔最大化

· **几何间隔与函数间隔关系**
- 几何间隔定义为点到超平面的欧氏距离，计算公式为 $y(w^Tx+b)/\|w\|$
- 函数间隔为分子部分 $y(w^Tx+b)$，具有缩放不变性缺陷；通过固定函数间隔为 1 消除自由度
- 选择 1 而非其他值为惯例，便于与 Hinge Loss 锚点对齐及保持数学形式简洁

· **硬间隔与软间隔原始问题**
- 硬间隔 SVM 要求所有样本函数间隔$\geqslant$1，对噪声敏感且线性不可分时可行解不存在
- 软间隔引入松弛变量 $\xi_i\geqslant 0$ 允许违规，目标函数增加 $C\sum\xi_i$ 惩罚项；C 越大容忍度越低
- 软间隔原始问题等价于最小化$\frac{1}{2}\|w\|^2 + C\sum\max(0, 1-y_i(w^Tx_i+b))$，即 L2 正则化加 Hinge Loss

· **Hinge Loss 特性与 SVM 优势**
- Hinge Loss 对正确分类且远离边界的样本给予零惩罚，仅关注边界附近支撑向量
- 高维特征空间中数据更易线性可分，SVM 凭借间隔最大化获得良好泛化能力
- 决策面仅限线性，非线性情形需后续引入核技巧与对偶形式解决

多分类策略与损失函数对比分析

· **一对多与一对一多分类方法**
- OvA 训练 K 个二分类器，每个区分一类与其余类，预测时选函数间隔最大者；需注意使用几何间隔需除以 $\|w\|$
- OvO 训练 C(K,2)个分类器覆盖所有类别对，预测采用多数投票；类别数大时训练成本过高
- 讲者坦言对选用函数间隔还是几何间隔无直觉判断，建议查阅现有 SVM 库源码或借助 AI 工具确认

· **四类损失函数锚点与性质**
- Zero-One、Hinge、Exponential 损失均通过(0,1)点，Logistic 损失因自然对数底通过$(0, \ln 2\approx 0.693)$
- 若 Logistic 损失改用 $\log_2$则同样通过(0,1)，四者在零点处对齐便于理论比较
- Logistic 损失对所有样本施加正惩罚，推动边界远离全部数据点；SVM 仅保证最小间隔，远点无额外推力
- Zero-One 损失梯度几乎处处为零，计算不可行，故采用 Hinge/Logistic 等凸代理损失替代

课程实验安排与补课日期确认

· **Logistic 回归实验与评估指标**

    - TA 团队提供 Jupyter Notebook 供学生实践 Logistic 回归，涵盖交叉熵损失与 Hinge 损失两种 formulations
    - 讲者将更新课件补充交叉熵推导过程，展示其与 Hinge 损失梯度等价性
    - 实验包含 Precision、Recall、Accuracy、F1 等评估指标的定义与代码实现
- **补课时间与辅导课安排**
    - 课后辅导课由博士后 Dr. Wang Zhen 于 11:30 开始带领
    - 因中秋国庆假期需补课，讲者初称 9 月 20 日（周日），学生当场提出应为 9 月 30 日
    - 讲者未现场确认正确日期，仅重复”September twenty/thirty”，具体补课时间待后续通知明确

待办事项

- @讲者 更新 Lecture Notes 补充 Cross Entropy 与 Hinge Loss 等价性推导
- @讲者或教务 确认补课确切日期（9 月 20 日或 30 日）并通知全体学生
- 1. Wang Zhen 主持课后 Tutorial 辅导（11:30 开始）
- @学生 完成 TA 提供的 Logistic 回归 Notebook 实验并理解评估指标实现