

本次课程讲解凸优化与 SVM。明确了凸问题局部最优即全局最优，推导了拉格朗日对偶函数及 KKT 条件；详解 SVM 软间隔对偶形式，引入核技巧解决非线性分类并降低计算复杂度；介绍 SMO 算法通过每次优化两个变量求解对偶问题。最后总结分类器选择依赖具体任务，无通用最优解，并布置了 SVM 代码实现作业。

凸集定义与局部全局最优证明

- **凸可行集的构造与验证**
  - 等式约束 $h_i(x)=0$ 可拆分为 $h_i(x)\le 0$ 与 $-h_i(x)\le 0$ 两个不等式，因等式约束要求 h_i 既凸又凹，故 h_i 必为仿射函数
  - 每个不等式约束定义一个凸集，每个等式约束定义一个超平面（亦为凸集），可行集为若干凸集之交，故仍为凸集
  - 凸优化问题的本质是在凸集上极小化凸函数；若目标或约束非凸，则不属于凸优化标准形式
- **局部最优即全局最优的反证法证明**
  - 假设 x^* 为局部最优但非全局最优，则存在可行点 y 使 $f_0(y)<f_0(x^*)$
  - 构造 $z=\theta y+(1-\theta)x^*$，选取 $\theta\in(0,1)$ 足够小使 z 落入 x^* 的局部邻域内；由可行集凸性知 z 可行
  - 由 f_0 凸性得 $f_0(z)\le\theta f_0(y)+(1-\theta)f_0(x^*)<f_0(x^*)$，与局部最优定义矛盾，故 x^* 必为全局最优
  - 证明关键：同时利用可行集凸性保证 z 可行、目标函数凸性保证 $f_0(z)$ 上界、局部最优定义给出 $f_0(z)$ 下界，三者缺一不可

拉格朗日对偶函数与下界性质

- **拉格朗日函数与对偶函数定义**
  - 标准型要求不等式约束写为 $f_i(x)\le 0$、等式约束写为 $h_i(x)=0$；若原式含负号或非零右端项，须移项整理
  - 拉格朗日函数 $L(x,\lambda,\nu)=f_0(x)+\sum_{i=1}^{m}\lambda_i f_i(x)+\sum_{j=1}^{p}\nu_j h_j(x)$，其中 λ 对应不等式、ν 对应等式
  - 对偶函数 $g(\lambda,\nu)=\inf_{x\in\mathcal{D}}L(x,\lambda,\nu)$，即使原问题非凸，$g$ 关于 (λ,ν) 恒为凹函数
  - g 可取 $-\infty$（当 inf 无下界时），但在其有效定义域内始终为凹

- **对偶函数凹性的直观解释**
  - 对固定 x，$L(x,\lambda,\nu)$ 关于 (λ,ν) 为仿射函数
  - g 为一族仿射函数的逐点下确界，而仿射函数族的逐点下确界必为凹函数
  - 图示：横轴为乘子，纵轴为 L 值；每条线对应一个 x，g 取所有线的最低包络，呈凹形
- **下界性质与弱对偶**
  - 若 $\lambda \geq 0$ 且 x 可行，则 $\sum \lambda_i f_i(x) \leq 0$、$\sum \nu_j h_j(x) = 0$，故 $L(x,\lambda,\nu) \leq f_0(x)$
  - 对所有可行 x 取下确界得 $g(\lambda,\nu) \leq p^*$，即对偶函数值恒为原问题最优值的下界
  - 弱对偶 $d^* \leq p^*$ 对任意优化问题（包括非凸）均成立，可用于评估近似解质量：若某可行解目标值接近 d^*，则该解接近最优
- **典型示例的对偶推导**
  - **线性方程组最小范数解**：$\min \| x \|^2$ s.t. $Ax = b$，令梯度 $\nabla_x L = 2x + A^\top \nu = 0$ 得 $x = -\frac{1}{2}A^\top \nu$，代回得 $g(\nu) = -\frac{1}{4}\nu^\top A A^\top \nu - b^\top \nu$，其 Hessian 为 $\frac{1}{2}AA^\top \succcurlyeq 0$，故 g 为凹
  - **线性规划**：$\min c^\top x$ s.t. $Ax = b, x \geq 0$，$L = c^\top x + \nu^\top (Ax - b) - \lambda^\top x = (c + A^\top \nu - \lambda)^\top x - b^\top \nu$；除非 $c + A^\top \nu - \lambda = 0$，否则 inf 为 $-\infty$；有限下界条件下 $g(\nu,\lambda) = -b^\top \nu$，且隐含约束 $A^\top \nu + c \geq 0$（因 $\lambda \geq 0$）

KKT 条件与强对偶性

- **强对偶与 Slater 条件**
  - 强对偶 $d^* = p^*$ 并非自动成立；对凸问题，若存在严格可行点（$f_i(x) < 0, h_j(x) = 0$），即满足 Slater 条件，则强对偶成立
  - 非凸问题一般不满足强对偶，但某些特殊结构下也可能成立
- **互补松弛条件**
  - 强对偶成立时，$p^* = d^* = g(\lambda^*,\nu^*) \leq L(x^*,\lambda^*,\nu^*) \leq f_0(x^*) = p^*$，中间不等式必取等
  - 由 $L(x^*,\lambda^*,\nu^*) = f_0(x^*) + \sum \lambda_i^* f_i(x^*)$ 且 $\lambda_i^* \geq 0, f_i(x^*) \leq 0$，得 $\lambda_i^* f_i(x^*) = 0$ 对所有 i 成立
  - 含义：若约束不起作用（$f_i(x^*) < 0$），则对应乘子 $\lambda_i^* = 0$；若 $\lambda_i^* > 0$，则约束必紧（$f_i(x^*) = 0$）
- **KKT 条件及其在凸问题中的充分性**
  - 四个条件：原始可行（$f_i(x) \leq 0, h_j(x) = 0$）、对偶可行（$\lambda \geq 0$）、互补松弛（$\lambda_i f_i(x) = 0$）、平稳性（$\nabla_x L = 0$）
  - 对一般问题，KKT 仅为必要条件（强对偶成立时）；对凸问题，KKT 为充要条件：满足 KKT 的点必为原始-对偶最优
  - 充分性证明：由平稳性与凸性知 x 最小化 $L(\cdot,\lambda,\nu)$；由互补松弛知 $L(x,\lambda,\nu) = f_0(x)$；结合弱对偶得 $f_0(x) = g(\lambda,\nu) \leq p^* \leq f_0(x)$，故等号成立

SVM 对偶形式推导与核技巧

- **软间隔 SVM 从原始到对偶的完整推导**
  - 原始问题：$\min_{w,b,\xi} \frac{1}{2}\| w \|^2 + C\sum \xi_i$ s.t. $y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$
  - 转为标准型后构建拉格朗日，引入 $\alpha_i \geq 0$ 对应函数间隔约束、$\beta_i \geq 0$ 对应 $\xi_i \geq 0$
  - 对 w, b, ξ 求偏导并令为零：$w = \sum \alpha_i y_i x_i$，$\sum \alpha_i y_i = 0$，$C - \alpha_i - \beta_i = 0$
  - 代回消去 w, b, ξ, β，得对偶问题：$\max_\alpha \sum \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j$，s.t. $\sum \alpha_i y_i = 0, 0 \leq \alpha_i \leq C$
- **α 的几何解释与支持向量稀疏性**
  - $\alpha_i = 0$：样本在间隔外侧，不参与法向量 w 的构成
  - $0 < \alpha_i < C$：样本恰在间隔边界上（$y_i(w^\top x_i + b) = 1$），用于计算偏置 b^*
  - $\alpha_i = C$：样本在间隔内侧或误分类侧，对应松弛变量 $\xi_i > 0$

- 仅 $\alpha_i > 0$ 的样本（支持向量）决定决策面；实际中支持向量占比很小，使模型高效

- **核技巧的计算优势与常见核函数**
  - 对偶形式中仅出现内积 $x_i^\top x_j$ 与 $x_i^\top x$；映射到高维 $\phi(x)$ 后，只需将内积替换为核函数 $K(x, x') = \phi(x)^\top \phi(x')$
  - 显式计算 $\phi(x)$ 再内积代价为 $O(n^2)$（n 为变换后维度），而核函数直接计算仅需 $O(d)$（d 为原始维度），此即核技巧
  - **多项式核**：$K(x, x') = (x^\top x')^p$，对应所有 p 阶及以下单项式组合的特征映射，维度有限
  - **RBF 核**：$K(x, x') = \exp(-\gamma \parallel x - x' \parallel^2)$，对应无穷维特征映射（由指数函数泰勒展开可知）；$\gamma$ 控制平滑度，小 γ 宽核平滑，大 γ 窄核敏感
  - 核函数选择决定决策面形状；多项式阶数越高、RBF 的 γ 越大，决策面越复杂
- **偏置 b 的计算方法**
  - 选取任一满足 $0 < \alpha_i < C$ 的支持向量 x_k，由 $y_k(w^{*\top} x_k + b^*) = 1$ 解出 $b^* = y_k - w^{*\top} x_k$
  - 实践中常取多个此类支持向量计算结果的平均值以提高数值稳定性

SMO 算法与分类器实践要点

- **坐标下降与 SMO 的设计动机**
  - 坐标下降每次仅优化一个坐标方向，固定其余变量；适用于低维或可分离问题，但对 SVM 对偶不适用
  - SMO 是坐标下降的特例，但每次联合优化两个变量 α_i, α_j，因为单一变量更新会违反线性等式约束 $\sum \alpha_i y_i = 0$
  - 两变量子问题可解析求解（等价于一维二次优化），避免数值迭代开销
- **SMO 的变量选择与收敛机制**
  - 外层启发式选择第一个变量（通常选最违反 KKT 条件的样本）
  - 内层选择第二个变量以最大化步长或基于其他启发式
  - 每次更新后维护等式约束，检查 KKT 违反程度作为收敛判据
  - 讲者指出 SMO 为串行算法，不易并行化；性能依赖数据分布与核矩阵缓存策略
- **分类器损失函数与实践建议**
  - 0-1 损失不可微； hinge 损失（SVM）、logistic 损失（逻辑回归）、指数损失（AdaBoost）均为其上界替代
  - KNN 无需训练，$k = 1$ 时有无限容量但泛化差；生成式模型估计类条件概率，判别式直接建模决策边界
  - 多分类可用 one-vs-rest；特征需归一化防止量纲主导；类别不平衡时调整权重或采样
  - 没有免费午餐定理：在所有可能目标函数上均匀平均，无任何学习算法优于其他；算法有效性依赖于问题特定假设
  - 特征工程仍重要，但端到端学习可联合优化特征表示与决策面；测试集必须独立于训练/验证集

关键决策与共识

- **凸优化理论基石确立**：局部最优即全局最优、对偶函数恒凹、弱对偶普适、凸问题下 KKT 充要，构成后续 SVM 推导的理论前提
- **SVM 对偶与核技巧绑定**：对偶形式天然适配核方法，使高维甚至无穷维特征空间下的非线性分类变得计算可行
- **SMO 为 SVM 训练的标准求解器**：利用对偶问题的特殊结构（线性等式+箱约束），通过双变量解析更新高效求解，尽管串行但实用性强

待办事项

- @学生 在提供的 ipynb notebook 中实现 SMO 算法，重点练习双变量选择启发式与解析更新步骤
- @学生 阅读课程可选材料中 SVM 简化版 SMO 算法说明，理解变量选择策略的设计考量
- @学生 查阅课件补充内容，复习三种非线性可分情形下特征映射的详细推导过程